

大模型AI Agent知识从0-1笔记-万字详解版本！

【Agent入门到实战】深度理解Agent全链路内容和深度优化、系统评估



1. 什么是Agent？为什么说它是AI的下一个战场

1.1 从ChatGPT到Agent的进化

想象一下这个场景：

传统的ChatGPT对话：

- 
- 你：「帮我规划一次周末去京都的旅行」
 - ChatGPT：「当然！京都是个美丽的城市，你可以考虑参观清水寺、金阁寺...建议提前预订酒店...」
 - 你：（需要自己去各个网站查机票、订酒店、规划路线）

AI Agent的体验：



- 你：「帮我规划一次周末去京都的旅行，预算5000元」
- Agent：（自动搜索机票价格）→（比较酒店并筛选）→（规划每日行程）→（计算预算）
- Agent：「已为您完成规划！往返机票1800元，住宿2晚1200元，包含清水寺、金阁寺等5个景点的详细行程，总预算4800元。[查看完整计划.pdf]」

这就是最本质的区别：ChatGPT给建议，Agent帮你干活。

1.2 Agent的核心定义

AI Agent（智能体）是一个具备以下三大能力的智能系统：


1. 自主感知：能够理解当前环境和任务需求
2. 自主决策：能够制定执行计划并动态调整
3. 自主执行：能够调用工具完成实际任务

用一句话总结：Agent = LLM（大脑）+ 工具（手脚）+ 记忆（经验）+ 规划（智慧）

AI Agent 的核心定义

不只是工具，而是能自主完成任务的智能体

一图看懂AI Agent




@周皓骏 其实飞书文档可以直接输入 Mermaid 代码，显示的图会清晰点，这里是有点模糊的图片

2. Agent核心架构深度剖析

2.1 Agent整体架构图

让我们先看一张完整的Agent架构图，理解各个组件如何协同工作：



2.2 架构分层解析

这个架构可以分为四个核心层：

第一层：感知层（Perception Layer）

这就是Agent比传统LLM强大的地方。



4月24日 14:22

这里的传统大模型的思考方式应当如何理解？



6月13日 20:53

传统大模型就是一问一答

- **作用：**接收并理解用户输入
- **组件：**用户输入 → 大语言模型理解
- **类比：**就像人的耳朵和眼睛

第二层：认知层（Cognition Layer）

- **作用：**分析、推理、规划
- **组件：**LLM Brain + 规划模块 + 推理引擎
- **类比：**就像人的大脑

第三层：执行层（Execution Layer）

- **作用：**调用各种工具完成任务
- **组件：**工具集（搜索、代码、API等）
- **类比：**就像人的手脚

第四层：记忆层（Memory Layer）

- **作用：**存储和检索信息
- **组件：**短期记忆 + 长期记忆
- **类比：**就像人的记忆系统

2.3 数据流转过程

让我用一个具体例子说明数据如何在架构中流转：

任务：「找出2024年诺贝尔物理学奖获得者，并总结他们的主要贡献」

代码块

```
1  步骤1：用户输入
2      → 进入规划模块：识别需要「搜索」和「总结」两个步骤
3
4  步骤2：规划完成
5      → 进入推理引擎（ReAct框架）
6
7  步骤3：第一轮思考-行动-观察循环
8      Thought: "我需要搜索2024年诺贝尔物理学奖获得者"
9      Action: 调用搜索工具search("2024 Nobel Prize Physics")
10     Observation: 获得搜索结果 → "John Hopfield和Geoffrey Hinton"
11
12 步骤4：第二轮思考-行动-观察循环
13     Thought: "我需要了解他们的贡献"
14     Action: 调用搜索工具search("Hopfield Hinton 神经网络贡献")
15     Observation: 获得详细信息 → "人工神经网络和机器学习基础"
16
17 步骤5：综合信息
18     → LLM整合所有观察结果
19     → 生成结构化答案
20     → 存入记忆模块（长期记忆）
21
22 步骤6：输出结果
23     → 返回完整答案给用户
```

这个过程中，Agent不是一次性生成答案，而是通过多轮思考-行动-观察的循环，逐步接近最终答案。这就是Agent比传统LLM强大的地方。



7月21日 00:58

传统大模型也有思考模式，有好几种。但明显标志就是一问一答，不会像 Agent 这样经过 actions loop 来回答你。

3. Agent的四大组成部分详解

3.1 组成部分总览



3.2 组成部分一：大语言模型（LLM Brain）

作用与地位

LLM是Agent的「大脑」，负责：

- 理解用户意图
- 生成推理过程
- 决策选择工具
- 综合信息输出

当前主流选择

模型	优势	适用场景	成本
GPT-4 / Claude	强大推理能力	复杂任务、高精度	高
DeepSeek-R1	性价比高、推理能力强	企业级部署	低
Gemini 2.0	多模态、Agent优化	需要视觉理解	中

实际代码示例

代码块

```
1  from langchain_openai import ChatOpenAI
2
3  # 初始化LLM作为Agent的大脑
4  llm = ChatOpenAI(
5      model="gpt-4",
6      temperature=0, # 降低随机性，提高推理稳定性
7  )
8
```

temperature=0,

7月20日 00:00

这个数值一般是怎么调？

7月20日 16:13

如果需要模型回答的内容更加发散就调高，数值区间啊为 0-1

```
9 # LLM的推理能力展示
10 response = llm.invoke(
11     "你需要查找2024年奥运会金牌榜，然后比较中美两国的金牌数。请分步思考如何完成这个任务。"
12 )
13 print(response.content)
14
15 # 输出示例：
16 # 思考步骤：
17 # 1. 首先需要调用搜索工具查找"2024奥运会金牌榜"
18 # 2. 从搜索结果中提取中国和美国的金牌数
19 # 3. 进行数值比较
20 # 4. 生成比较结果
```

关键点：

- temperature=0：让Agent在推理时更稳定、更可预测
- 提示词需要引导「分步思考」，这是CoT（Chain of Thought）的核心

3.3 组成部分二：规划模块（Planning）

为什么需要规划？

举个例子：如果任务是「帮我准备一场技术分享会」，没有规划的Agent会：

- 不知道从哪开始
- 可能遗漏重要步骤
- 浪费大量token重复思考

有规划的Agent会：

代码块

- 确定主题和目标听众
- 搜索相关技术资料
- 设计PPT大纲
- 准备演示Demo
- 生成演讲稿

两种主流规划方法

方法一：ReAct框架（边想边做）



ReAct特点：


- ✓ 灵活：可以根据中间结果调整计划
- ✓ 适合探索性任务
- ✗ Token消耗大：每一步都要调用LLM

方法二：Plan-and-Execute（先计划后执行）

from langchain.agents import create_r...

7月10日 13:24
这是旧版的 langchain 写法发吧，现在都是 1.x，太老旧了

7月20日 14:16
已经有新的了 可以找顾问老师那边了解下 新的是 1.x 的 langchain 和 langgraph



Plan-and-Execute特点:

- 高效: 只需调用一次LLM规划
- 可并行执行多个任务
- 不灵活: 难以根据中间结果调整

实际代码对比

ReAct实现:

代码块

```
1  from langchain.agents import create_react_agent, AgentExecutor
2  from langchain.tools import Tool
3
4  # 定义工具
5  search_tool = Tool(
6      name="Search",
7      func=search_function,
8      description="搜索互联网信息"
9  )
10
11 # 创建ReAct Agent
12 agent = create_react_agent(llm, [search_tool])
13 agent_executor = AgentExecutor(agent=agent, tools=[search_tool],
14                                verbose=True)
15
16 # 执行任务
17 result = agent_executor.invoke({
18     "input": "找出DeepSeek-R1的训练成本，并与GPT-4对比"
19 })
20
21 # 输出过程 (verbose=True会显示) :
22 # Thought: 我需要搜索DeepSeek-R1的信息
23 # Action: Search("DeepSeek-R1 training cost")
24 # Observation: [搜索结果]
25 # Thought: 接下来需要搜索GPT-4的成本
26 # Action: Search("GPT-4 training cost")
27 # Observation: [搜索结果]
28 # Thought: 现在可以进行对比了
```

Plan-and-Execute实现：

代码块

```
1  from langchain.agents import Plan, Execute
2
3  # 第一步：规划
4  planner = create_planner(llm)
5  plan = planner.plan("分析2024年AI Agent市场趋势")
6
7  # 输出的计划：
8  # Task 1: 搜索2024年AI Agent市场报告
9  # Task 2: 提取市场规模数据
10 # Task 3: 识别主要参与者
11 # Task 4: 总结趋势和预测
12
13 # 第二步：执行
14 executor = create_executor(tools)
15 results = executor.execute(plan) # 按计划依次执行
```

帮我推荐北京的餐厅



5月23日 16:53

帮我推荐餐厅？

选择建议

- 探索性任务（不知道中间会遇到什么）→ 用ReAct
- 流程明确的任务（步骤固定）→ 用Plan-and-Execute
- 复杂混合任务 → 两者结合

3.4 组成部分三：记忆模块（Memory）

为什么记忆很重要？

想象你在和一个朋友聊天：

- 没有记忆：每次对话都是新的，对方完全不记得你之前说过什么
- 有记忆：对方记得你的喜好、之前的讨论，对话更流畅

Agent也一样。记忆分为两类：

短期记忆（Short-term Memory）

作用：保存当前任务的上下文

存储内容：

- 当前对话历史
- 中间步骤的结果
- 临时变量和状态

技术实现：

代码块

```
1  from langchain.memory import ConversationBufferMemory
2
3  # 创建对话记忆
4  memory = ConversationBufferMemory(
5      memory_key="chat_history",
6      return_messages=True
7  )
8
```



```
9  # Agent执行时自动记录
10 agent_executor = AgentExecutor(
11     agent=agent,
12     tools=tools,
13     memory=memory,  # 添加记忆
14     verbose=True
15 )
16
17 # 第一轮对话
18 agent_executor.invoke({"input": "我叫张三，在北京工作"})
19
20 # 第二轮对话 (Agent会记得上下文)
21 agent_executor.invoke({"input": "帮我推荐北京的餐厅"})
22 # Agent会知道你在北京，直接推荐北京的餐厅
```

短期记忆的挑战：

- 📊 **Token限制**：GPT-4有128K token限制，长对话会超出
- 💰 **成本问题**：每次调用都要把整个历史发送给LLM

解决方案：

代码块

```
1  from langchain.memory import ConversationSummaryMemory
2
3  # 使用摘要记忆：自动总结历史对话
4  summary_memory = ConversationSummaryMemory(
5      llm=llm,
6      max_token_limit=2000  # 超过限制时自动总结
7  )
8
9  # 效果：
10 # 原始历史 (5000 tokens) → 总结后 (500 tokens)
11 # "用户是张三，在北京工作，偏好川菜，预算500元以内"
```

长期记忆（Long-term Memory）

作用：存储可复用的知识和经验

存储内容：

- 用户的个人信息和偏好
- 历史任务的成功经验
- 领域知识库
- 工具使用的最佳实践

技术实现：使用向量数据库

代码块

```
1  from langchain.vectorstores import Chroma
2  from langchain.embeddings import OpenAIEmbeddings
3
4  # 1. 创建向量数据库（长期记忆）
5  embeddings = OpenAIEmbeddings()
6  vectorstore = Chroma(
7      collection_name="agent_memory",
8      embedding_function=embeddings
9  )
10
```

重要性评分的记忆管理




4月24日 14:30

重要性评分的运作机制是？

```
11 # 2. 存储经验
12 vectorstore.add_texts([
13     "用户张三偏好川菜，预算500元",
14     "北京最佳川菜馆：川办、巴国布衣",
15     "搜索餐厅时应该考虑：位置、评分、价格、口味"
16 ])
17
18 # 3. Agent执行任务时检索相关记忆
19 query = "帮张三推荐餐厅"
20 relevant_memories = vectorstore.similarity_search(query, k=3)
21
22 # 4. 将记忆注入到prompt中
23 prompt = f"""
24 相关记忆：
25 {relevant_memories}
26
27 用户请求：{query}
28
29 请根据记忆中的信息给出推荐。
30 """
```

记忆架构图



记忆模块的高级技巧

技巧1：自动清理不重要的记忆

代码块

```
1 #基于重要性评分的记忆管理
```

```
2 def should_store_in_long_term(message):
3     # 让LLM判断是否重要
4     importance = llm.predict(f"这条信息的重要性 (1-10) : {message}")
5     return int(importance) >= 7 # 只存储重要度>=7的信息
```

技巧2：记忆的时效性管理

代码块

```
1 #给记忆加上时间戳
2 from datetime import datetime, timedelta
3
4 memory_item = {
5     "content": "用户偏好川菜",
6     "timestamp": datetime.now(),
7     "expiry": datetime.now() + timedelta(days=30) # 30天后过期
8 }
9
10 # 检索时过滤过期记忆
11 def get_valid_memories():
12     return [m for m in memories if m["expiry"] > datetime.now()]
```

3.5 组成部分四：工具集（Tools）

工具是Agent的「超能力」

如果说LLM是Agent的大脑，那工具就是Agent的「手脚」和「超能力」。通过工具，Agent可以：

- 🔍 搜索互联网
- 💻 执行代码
- 📊 操作数据库
- 🔧 调用API
- 🖥️ 控制电脑

工具的定义与实现

一个工具的标准结构：

代码块

```
1 from langchain.tools import Tool
2
3 def calculate(expression: str) -> str:
4     """执行数学计算"""
5     try:
6         result = eval(expression) # 实际生产中不要用eval
7         return f"计算结果: {result}"
8     except Exception as e:
9         return f"计算错误: {str(e)}"
10
11 # 定义工具
12 calculator_tool = Tool(
13     name="Calculator", # 工具名称 (Agent会看到)
14     func=calculate, # 工具函数
15     description="""
16     用于数学计算。
17     输入：数学表达式字符串，如 "2 + 2" 或 "sqrt(16)"
18     输出：计算结果
19 """
```

```
19     何时使用：当需要进行精确数学计算时
20     """ # 描述很重要！Agent通过描述来决定是否使用该工具
21 )
```

关键要素：

- 1. 清晰的名称：Agent通过名称快速识别工具
- 2. 详细的描述：告诉Agent什么时候用、怎么用
- 3. 标准的输入输出：保证工具能被正确调用

常用工具类型与实现

1. 搜索工具

代码块

```
1  from langchain.tools import DuckDuckGoSearchRun
2
3  search = DuckDuckGoSearchRun()
4
5  search_tool = Tool(
6      name="WebSearch",
7      func=search.run,
8      description="搜索互联网获取最新信息。适用于需要实时数据的场景。"
9  )
10
11  # 使用示例
12  result = search.run("2024年诺贝尔物理学奖")
```

2. 代码执行工具

代码块

```
1  def python_executor(code: str) -> str:
2      """执行Python代码"""
3      import io
4      import sys
5      from contextlib import redirect_stdout
6
7      f = io.StringIO()
8      try:
9          with redirect_stdout(f):
10              exec(code)
11              return f.getvalue()
12      except Exception as e:
13          return f"错误: {str(e)}"
14
15  code_tool = Tool(
16      name="PythonExecutor",
17      func=python_executor,
18      description="执行Python代码。适用于数据处理、计算、可视化等任务。"
19  )
20
21  # Agent可以这样用：
22  # code_tool.run("""
23  # import pandas as pd
24  # data = [1, 2, 3, 4, 5]
25  # print(f"平均值: {sum(data)/len(data)}")
26  # """)
```

3. API调用工具

代码块

```
1  import requests
2
3  def weather_api(city: str) -> str:
4      """查询天气"""
5      # 假设调用某个天气API
6      response = requests.get(f"https://api.weather.com/{city}")
7      return response.json()
8
9  weather_tool = Tool(
10     name="WeatherAPI",
11     func=weather_api,
12     description="查询指定城市的天气信息。输入城市名，返回温度、湿度等信
        息。"
13 )
```

4. 数据库工具

代码块

```
1  import sqlite3
2
3  def query_database(sql: str) -> str:
4      """查询数据库"""
5      conn = sqlite3.connect('my_database.db')
6      cursor = conn.cursor()
7      try:
8          cursor.execute(sql)
9          results = cursor.fetchall()
10         return str(results)
11     except Exception as e:
12         return f"查询错误: {str(e)}"
13     finally:
14         conn.close()
15
16  db_tool = Tool(
17     name="DatabaseQuery",
18     func=query_database,
19     description="执行SQL查询。适用于需要从数据库获取数据的场景。"
20 )
```

工具组合的实际案例

案例：构建一个数据分析Agent

代码块

```
1  from langchain.agents import create_react_agent, AgentExecutor
2  from langchain_openai import ChatOpenAI
3
4  # 1. 准备工具集
5  tools = [
6      search_tool,      # 搜索数据
7      code_tool,        # 数据处理
8      db_tool,          # 数据库查询
9  ]
10
11  # 2. 创建Agent
```

```
12 llm = ChatOpenAI(model="gpt-4", temperature=0)
13 agent = create_react_agent(llm, tools)
14 agent_executor = AgentExecutor(agent=agent, tools=tools,
    verbose=True)
15
16 # 3. 执行复杂任务
17 result = agent_executor.invoke({
18     "input": """
19     帮我分析一下：
20     1. 从数据库中查询2024年的销售数据
21     2. 搜索行业平均增长率
22     3. 用Python计算我们的增长率
23     4. 对比并给出结论
24     """
25 })
26
27 # Agent的执行过程：
28 # Thought: 需先从数据库获取数据
29 # Action: DatabaseQuery("SELECT * FROM sales WHERE year=2024")
30 # Observation: [...数据...]
31 #
32 # Thought: 需要搜索行业数据
33 # Action: WebSearch("2024年销售行业平均增长率")
34 # Observation: [...行业数据...]
35 #
36 # Thought: 现在可以计算了
37 # Action: PythonExecutor("
38 #     our_growth = (current - previous) / previous * 100
39 #     industry_avg = 15.2
40 #     print(f'我们的增长率: {our_growth}%, 行业平均: {industry_avg}%')
41 # ")
42 # Observation: 我们的增长率: 18.5%, 行业平均: 15.2%
43 #
44 # Thought: 可以给出结论了
45 # Final Answer: [完整分析报告]
```

工具使用的最佳实践

实践1：工具描述要精确

✗ 不好的描述：

代码块

```
1 description="一个搜索工具"
```

✓ 好的描述：

代码块

```
1 description="""
2 搜索互联网获取最新信息。
3  - 输入：搜索关键词（字符串）
4  - 输出：相关网页内容摘要
5  - 适用场景：需要实时数据、最新新闻、当前事件
6  - 不适用场景：历史数据、个人信息、数学计算
7  """
```

实践2：工具要有错误处理


```
代码块def safe_tool(input_data):
2     try:
3         # 工具的实际逻辑
4         result = process(input_data)
5         return result
6     except Exception as e:
7         # 返回友好的错误信息，帮助Agent调整策略
8         return f"工具执行失败：{str(e)}。建议：尝试其他方法或简化输入。"
```

实践3：工具要有使用日志


```
代码块
1  import logging
2
3  def logged_tool(input_data):
4      logging.info(f"工具被调用，输入：{input_data}")
5      result = execute(input_data)
6      logging.info(f"工具执行完成，输出：{result}")
7      return result
```

4. Agent的工作原理与理解方式

4.1 ReAct框架深度解析

ReAct（Reasoning + Acting）是目前最主流的Agent工作框架，由Google Brain研究团队提出。

ReAct的核心循环



完整的ReAct示例

任务：「2024年哪个国家赢得了最多的奥运金牌？这个国家的首都是哪里？」

Agent的完整思考过程：

```
代码块
1  === 第一轮循环 ===
2
3  Thought 1:
4  "我需要找到2024年奥运会的金牌榜信息。这需要搜索最新的数据。"
5
6  Action 1:
7  Tool: WebSearch
8  Input: "2024奥运会金牌榜"
9
10 Observation 1:
```

```
11  "2024年巴黎奥运会，美国队以40枚金牌位居榜首，中国队38枚金牌第二..."
12
13  === 第二轮循环 ===
14
15  Thought 2:
16  "好的，美国赢得了最多的金牌。现在我需要确认美国的首都。虽然我知道是华盛顿
    D.C.，但为了确保准确性，我应该验证一下。"
17
18  Action 2:
19  Tool: WebSearch
20  Input: "美国首都"
21
22  Observation 2:
23  "美国的首都是华盛顿哥伦比亚特区（Washington, D.C.）..."
24
25  === 完成 ===
26
27  Thought 3:
28  "我已经获得了所有需要的信息，可以回答了。"
29
30  Final Answer:
31  "2024年巴黎奥运会，美国赢得了最多的金牌（40枚）。美国的首都是华盛顿哥伦比亚
    特区（Washington, D.C.）。"
```

ReAct的代码实现

```
代码块

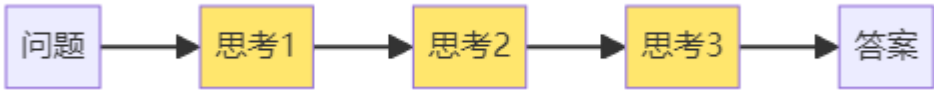
1  from langchain.agents import create_react_agent, AgentExecutor
2  from langchain_openai import ChatOpenAI
3  from langchain.tools import Tool
4  from langchain.prompts import PromptTemplate
5
6  # 1. 定义ReAct的提示词模板
7  react_prompt = PromptTemplate.from_template("""
8  你是一个AI助手，通过推理和行动来解决问题。
9
10  可用工具：
11  {tools}
12
13  使用以下格式：
14
15  Question: 需要回答的问题
16  Thought: 你应该思考该做什么
17  Action: 要采取的行动，必须是[{tool_names}]之一
18  Action Input: 行动的输入
19  Observation: 行动的结果
20  ...（这个Thought/Action/Action Input/Observation可以重复N次）
21  Thought: 我现在知道最终答案了
22  Final Answer: 原始问题的最终答案
23
24  开始！
25
26  Question: {input}
27  Thought: {agent_scratchpad}
28  """)
29
30  # 2. 创建工具
31  def search(query):
32      # 简化的搜索实现
33      if "金牌" in query:
```

```
34         return "2024年巴黎奥运会美国队40枚金牌第一"
35     elif "首都" in query:
36         return "美国首都是华盛顿D.C."
37
38     search_tool = Tool(
39         name="Search",
40         func=search,
41         description="搜索互联网信息"
42     )
43
44     # 3. 创建Agent
45     llm = ChatOpenAI(model="gpt-4", temperature=0)
46     agent = create_react_agent(
47         llm=llm,
48         tools=[search_tool],
49         prompt=react_prompt
50     )
51
52     agent_executor = AgentExecutor(
53         agent=agent,
54         tools=[search_tool],
55         verbose=True, # 显示详细过程
56         max_iterations=5 # 最多5轮循环
57     )
58
59     # 4. 执行任务
60     result = agent_executor.invoke({
61         "input": "2024年哪个国家赢得了最多的奥运金牌？这个国家的首都是哪里？"
62     })
63
64     print(result["output"])
```

4.2 其他Agent工作模式

除了ReAct，还有其他几种重要的工作模式：

模式1：Chain of Thought (CoT) - 纯推理



特点：


- 只有思考，没有行动
- 适合纯逻辑推理问题
- Token消耗少

示例：

代码块

```
1  问题: "如果一个房间有3只猫，每只猫前面有2只猫，那一共有多少只猫？"
2
3  CoT推理:
4  思考1: 题目说"每只猫前面有2只猫"
5  思考2: 这意味着猫排成一排
6  思考3: 但只有3只猫，所以是循环的或者交叉的排列
7  思考4: 实际上还是3只猫
8  答案: 3只猫
```

模式2：Plan-and-Execute - 先计划后执行



特点：


- 先一次性规划，再按计划执行
- 可以并行执行任务
- 适合流程明确的复杂任务

代码示例：

代码块

```
1  #1. 规划阶段
2  planner_prompt = """
3  将任务分解为子任务：
4  任务：{task}
5
6  请输出JSON格式的任务列表：
7  [
8      {"id": 1, "description": "...", "dependencies": []},
9      {"id": 2, "description": "...", "dependencies": [1]},
10     ...
11 ]
12 """
13
14 plan = llm.invoke(planner_prompt.format(
15     task="分析竞争对手的产品策略"
16 ))
17
18 # 2. 执行阶段
19 for task in plan:
20     if all_dependencies_completed(task):
21         result = execute_task(task)
22         store_result(task.id, result)
```

模式3：Self-Ask - 自问自答



示例：

代码块

```
1 主问题: "iPhone 15的屏幕比iPhone 14大多少? "  
2  
3 Agent自问自答:  
4 Q1: "iPhone 15的屏幕尺寸是多少? "  
5 → 搜索得到: 6.1英寸  
6  
7 Q2: "iPhone 14的屏幕尺寸是多少? "  
8 → 搜索得到: 6.1英寸  
9  
10 Q3: "6.1英寸 - 6.1英寸 = ?"  
11 → 计算得到: 0英寸  
12  
13 最终答案: "iPhone 15和iPhone 14的屏幕尺寸相同, 都是6.1英寸。"
```

4.3 理解Agent的三种视角

视角1：把Agent看作「员工」

代码块

```
1 你（老板）：「帮我准备明天的演讲PPT」  
2  
3 Agent（员工）：  
4 理解需求（演讲主题、目标听众）  
5 搜索资料（行业数据、案例）  
6 设计大纲（结构规划）  
7 制作PPT（使用工具）  
8 审核优化（自我检查）  
9 交付成果（PPT文件）
```

这个视角帮助你：

- 设计Agent的职责范围
- 定义输入输出格式
- 考虑错误处理

视角2：把Agent看作「循环系统」

代码块

```
1  输入 → [感知 → 思考 → 决策 → 行动 → 观察] → 输出
2              ↑
3              |
              反馈循环
```

这个视角帮助你：

- 优化循环次数
- 设置终止条件
- 调试中间过程

视角3：把Agent看作「大脑+工具」

代码块

```
1  大脑（LLM）：
2      理解语言
3      推理规划
4      生成文本
5
6  ↓ 通信
7
8  工具箱：
9      搜索引擎
10     计算器
11     API接口
12     数据库
```

这个视角帮助你：

- 扩展Agent能力（添加新工具）
- 优化工具选择（描述要精确）
- 提升执行效率（工具要快）

5. 构建Agent的五大难点与解决方案

5.1 难点一：无限循环与任务卡死

问题描述

Agent可能陷入死循环：

代码块

```
1  Thought: 我需要搜索信息
2  Action: Search("2024 AI")
3  Observation: [搜索结果]
4
5  Thought: 我需要搜索更详细的信息
```



```
6 Action: Search("2024 AI详细")
7 Observation: [搜索结果]
8
9 Thought: 我需要搜索更详细的信息
10 Action: Search("2024 AI更详细")
11 ... (永远循环)
```

解决方案

方案1：设置最大迭代次数

代码块

```
1 agent_executor = AgentExecutor(
2     agent=agent,
3     tools=tools,
4     max_iterations=10, # 最多执行10轮
5     max_execution_time=60, # 最多执行60秒
6     early_stopping_method="generate" # 超时生成答案
7 )
```

方案2：优化提示词，明确终止条件

代码块

```
1 prompt = """
2 你必须在5步内完成任务。
3 如果5步内无法完成，请给出"基于现有信息的最佳答案"。
4
5 当前已经执行了{iterations}步。
6 """
```

方案3：实现智能终止判断

代码块

```
1 def should_continue(agent_state):
2     # 检查是否在重复相同的行动
3     last_3_actions = agent_state.history[-3:]
4     if len(set(last_3_actions)) == 1: # 最后3个动作都相同
5         return False # 终止
6
7     # 检查是否进展缓慢
8     if agent_state.iterations > 5 and not
9         has_new_info(agent_state):
10         return False
11     return True
```

5.2 难点二：工具选择错误

问题描述

代码块

```
1 Agent选择了错误的工具：
2 任务: "计算2024年有多少天"
3
4 错误选择：
```

```
5 Action: WebSearch("2024年有多少天") ❌ 不需要搜索
6
7 正确选择:
8 Action: Calculator("365 if not is_leap_year(2024) else 366") ✅
```

根本原因

- 1. 工具描述不清晰
- 2. Prompt没有给出使用规则
- 3. LLM对任务理解有偏差

解决方案

方案1：改进工具描述

```
代码块
1  ❌ 不好的描述
2  calculator_tool = Tool(
3      name="Calculator",
4      description="计算"
5  )
6
7  # ✅ 好的描述
8  calculator_tool = Tool(
9      name="Calculator",
10     description="""
11     用于精确的数学计算。
12
13     适用场景：
14     - 算术运算（加减乘除）
15     - 数学函数（平方、开方、三角函数）
16     - 逻辑判断（比较大小）
17
18     输入格式：Python数学表达式字符串
19     示例: "2 + 2", "sqrt(16)", "2024 % 4 == 0"
20
21     不适用场景：
22     - 需要最新数据（用Search）
23     - 需要上下文信息（用Memory）
24     """
25  )
```

方案2：添加工具使用示例

```
代码块
1  prompt = """
2  工具使用示例:
3
4  问题: "今天的天气如何? "
5  正确: Action: WeatherAPI("北京")
6  错误: Action: Calculator("天气") # 天气不是数学问题
7
8  问题: "2的100次方是多少? "
9  正确: Action: Calculator("2**100")
10  错误: Action: Search("2的100次方") # 不需要搜索
11
12  现在请处理: {input}
```

13 """

方案3：实现工具推荐系统

代码块

```
1 def recommend_tool(task_description, available_tools):
2     """根据任务描述推荐工具"""
3     # 使用LLM分析任务
4     analysis = llm.invoke(f"""
5     任务: {task_description}
6
7     请分析这个任务需要：
8     1. 实时数据吗？ → 需要Search
9     2. 数学计算吗？ → 需要Calculator
10    3. 历史信息吗？ → 需要Memory
11
12    推荐工具（JSON格式）：
13    [{"recommended": ["tool1", "tool2"], "reason": "..."}]
14    """)
15
16    return analysis.recommended
```

5.3 难点三：上下文窗口溢出

问题描述

长对话或复杂任务会导致：

代码块

```
1 Prompt + 历史对话 + 工具描述 + 中间结果 = 超过Token限制
2
3 GPT-4：128K tokens
4 Claude：200K tokens
5
6 一次复杂任务可能消耗50K+ tokens
7 → 超出限制或成本过高
```

解决方案

方案1：智能压缩上下文

代码块

```
1 from langchain.memory import ConversationSummaryBufferMemory
2
3 memory = ConversationSummaryBufferMemory(
4     llm=llm,
5     max_token_limit=4000, # 保留最近4000 tokens
6     moving_summary_buffer="", # 旧的对话自动总结
7 )
8
9 # 效果：
10 # 旧对话: "用户询问了天气、新闻、股票...共20轮对话"
11 # ↓ 总结为
12 # "用户主要关心北京天气（晴）、今日新闻（AI发展）、股票（上涨）"
```

方案2：分层记忆

代码块

```
1 class HierarchicalMemory:
2     def init(self):
3         self.recent_memory = [] # 最近3轮, 完整保留
4         self.mid_term_memory = [] # 中期10轮, 保留关键信息
5         self.long_term_memory = vectorstore # 长期, 向量检索
6
7     def add(self, message):
8         self.recent_memory.append(message)
9
10        if len(self.recent_memory) > 3:
11            # 移到中期记忆, 提取关键信息
12            old_message = self.recent_memory.pop(0)
13            key_info = extract_key_info(old_message)
14            self.mid_term_memory.append(key_info)
15
16            if len(self.mid_term_memory) > 10:
17                # 移到长期记忆, 存入向量库
18                old_info = self.mid_term_memory.pop(0)
19                self.long_term_memory.add_texts([old_info])
20
21        def get_context(self, query):
22            # 组合三层记忆
23            recent = "\n".join(self.recent_memory)
24            mid = "\n".join(self.mid_term_memory)
25            relevant = self.long_term_memory.similarity_search(query,
26                                                                k=2)
27
28            return f"{recent}\n\n相关历史: {mid}\n{relevant}"
```

方案2: Agent层面的降级策略



2025年12月25日

tt

方案3: 动态工具加载

代码块

```
1 #不要一次性加载所有工具
2 all_tools = {
3     "search": search_tool,
4     "calculator": calc_tool,
5     "database": db_tool,
6     "api": api_tool,
7     # ... 50个工具
8 }
9
10 # 根据任务动态选择工具
11 def select_tools(task):
12     # 分析任务需要哪些类别的工具
13     if "搜索" in task or "查询" in task:
14         return [all_tools["search"]]
15     elif "计算" in task:
16         return [all_tools["calculator"]]
17     # ...
18
19     # 默认返回最常用的5个工具
20     return list(all_tools.values())[:5]
21
22 # 创建Agent时只加载需要的工具
23 tools = select_tools(user_input)
24 agent = create_agent(llm, tools)
```

5.4 难点四：错误处理与鲁棒性

问题描述

各种错误会导致Agent崩溃：

- 工具调用失败
- API超时
- 返回格式错误
- LLM输出异常

解决方案

方案1：工具层面的错误处理

代码块

```
1 def robust_tool(func):
2     """装饰器：让工具更健壮"""
3     def wrapper(*args, **kwargs):
4         max_retries = 3
5         for attempt in range(max_retries):
6             try:
7                 result = func(*args, **kwargs)
8                 return {
9                     "success": True,
10                    "data": result
11                }
12            except TimeoutError:
13                if attempt == max_retries - 1:
14                    return {
15                        "success": False,
16                        "error": "工具执行超时，请尝试简化输入或使用其他
17                    工具"
18                    }
19                time.sleep(2 ** attempt) # 指数退避
20            except Exception as e:
21                return {
22                    "success": False,
23                    "error": f"工具执行失败: {str(e)}"
24                }
25        return wrapper
26
27 @robust_tool
28 def search_tool(query):
29     # 实际搜索逻辑
30     return search_engine.query(query)
```

方案2：Agent层面的降级策略

代码块

```
1 class RobustAgent:
2     def execute(self, task):
3         try:
4             # 尝试完整流程
5             return self.full_execution(task)
6         except AgentError:
7             # 降级：使用简化流程
8             return self.simplified_execution(task)
9         except Exception:
```

```

10         # 最终降级：直接用LLM回答
11         return self.fallback_execution(task)
12
13     def full_execution(self, task):
14         # ReAct完整循环，可能使用多个工具
15         return self.react_loop(task)
16
17     def simplified_execution(self, task):
18         # 简化版：只用一个最重要的工具
19         tool = self.select_best_tool(task)
20         result = tool.run(task)
21         return self.llm.summarize(result)
22
23     def fallback_execution(self, task):
24         # 保底：直接用LLM知识回答
25         return self.llm.invoke(f"请基于你的知识回答：{task}")

```

方案3：实时监控与告警

代码块

```

1  import logging
2
3  class AgentMonitor:
4      def init(self):
5          self.metrics = {
6              "total_tasks": 0,
7              "success": 0,
8              "failures": 0,
9              "avg_time": 0,
10         }
11
12     def log_execution(self, task, result, duration):
13         self.metrics["total_tasks"] += 1
14
15         if result["success"]:
16             self.metrics["success"] += 1
17         else:
18             self.metrics["failures"] += 1
19             logging.error(f"Task failed: {task}, Error: {result['error']}")
20
21         # 计算平均时间
22         self.metrics["avg_time"] = (
23             self.metrics["avg_time"] *
24             (self.metrics["total_tasks"] - 1) + duration
25         ) / self.metrics["total_tasks"]
26
27         # 告警
28         failure_rate = self.metrics["failures"] /
29         self.metrics["total_tasks"]
30         if failure_rate > 0.3: # 失败率超过30%
31             send_alert(f"Agent failure rate: {failure_rate:.2%}")

```

5.5 难点五：成本控制

问题描述

Agent的成本可能很高：

代码块 次复杂任务：

2 10轮ReAct循环

3 每轮2K tokens输入 + 500 tokens输出

4 总计：(2000+500) * 10 = 25K tokens

5

6 GPT-4价格（假设）：

7 输入：\$0.03 / 1K tokens

8 输出：\$0.06 / 1K tokens

9

10 单次任务成本：

11 输入：20K * 0.03 = \$0.60

12 输出：5K * 0.06 = \$0.30

13 总计：\$0.90

14

15 如果每天1000个任务 = \$900/天 = \$27,000/月

解决方案

方案1：模型分级使用

代码块

```
1  class CostOptimizedAgent:
2      def init(self):
3          self.models = {
4              "cheap": ChatOpenAI(model="gpt-3.5-turbo"), #
5              $0.002/1K
6              "standard": ChatOpenAI(model="gpt-4"), #
7              $0.03/1K
8              "premium": ChatOpenAI(model="gpt-4-turbo"), #
9              $0.01/1K
10         }
11
12     def select_model(self, task_complexity):
13         # 简单任务用便宜模型
14         if task_complexity < 3:
15             return self.models["cheap"]
16         elif task_complexity < 7:
17             return self.models["standard"]
18         else:
19             return self.models["premium"]
20
21     def estimate_complexity(self, task):
22         # 根据任务特征估计复杂度
23         factors = {
24             "num_steps": len(parse_steps(task)) * 2,
25             "need_tools": 3 if requires_tools(task) else 0,
26             "domain_specific": 2 if is_specialized(task) else 0,
27         }
28         return sum(factors.values())
```

方案2：缓存机制

代码块

```
1  from functools import lru_cache
2  import hashlib
3
4  class CachedAgent:
5      def init(self):
```



```
6         self.cache = {}
7
8     def execute(self, task):
9         # 计算任务的哈希值
10        task_hash = hashlib.md5(task.encode()).hexdigest()
11
12        # 检查缓存
13        if task_hash in self.cache:
14            logging.info(f"Cache hit for task: {task[:50]}...")
15            return self.cache[task_hash]
16
17        # 执行任务
18        result = self.agent.run(task)
19
20        # 存入缓存
21        self.cache[task_hash] = result
22        return result
23
24    # 效果：
25    # 第一次: "北京明天天气" → 调用LLM → 成本$0.05
26    # 第二次: "北京明天天气" → 从缓存读取 → 成本$0
```

方案3：批处理

代码块

```
1  def batch_process(tasks):
2      """批量处理相似任务"""
3      # 将相似任务分组
4      groups = group_similar_tasks(tasks)
5
6      results = []
7      for group in groups:
8          # 一次性处理一组任务
9          batch_prompt = f"""
10         请处理以下{len(group)}个相似任务：
11         {"\n".join([f"{i+1}. {t}" for i, t in enumerate(group)])}
12
13         请输出JSON格式的结果列表。
14         """
15
16         batch_result = llm.invoke(batch_prompt)
17         results.extend(parse_batch_result(batch_result))
18
19     return results
20
21    # 效果：
22    # 单独处理10个任务：10次LLM调用
23    # 批量处理10个任务：2-3次LLM调用（节省70%成本）
```

方案4：设置预算限制

代码块

```
1  class BudgetControlledAgent:
2      def init(self, daily_budget_usd=10):
3          self.daily_budget = daily_budget_usd
4          self.today_spent = 0
5          self.task_count = 0
6
```

| 并行工作



5月7日 15:31（编辑过）

这是个有问题的案例，上述几个步骤理论上只能串行，需求都没有咋系统设计，这里更应该强调的是专业分工 → 质量更高


```
7         def execute(self, task):
8             # 检查预算
9             estimated_cost = self.estimate_cost(task)
10            if self.today_spent + estimated_cost > self.daily_budget:
11                return {
12                    "success": False,
13                    "message": f"预算不足。今日已用
14                    ${self.today_spent:.2f}, 预算${self.daily_budget}"
15                }
16            # 执行任务
17            result = self.agent.run(task)
18            actual_cost = self.calculate_cost(result.tokens_used)
19
20            # 更新统计
21            self.today_spent += actual_cost
22            self.task_count += 1
23
24            logging.info(f"Task {self.task_count}: Cost
25            ${actual_cost:.4f}, Total ${self.today_spent:.2f}")
26
27            return result
```

6. 多Agent协同系统设计


6.1 为什么需要多Agent?

单个Agent的局限性：

代码块


- 1 假设你要开发一个完整的软件产品：
- 2
- 3 单Agent模式：
- 4 Agent：「我既要写需求文档，又要写代码，还要测试，还要设计UI…」
- 5 → 能力有限
- 6 → 容易出错
- 7 → 效率低下
- 8
- 9 多Agent模式：
- 10 产品经理Agent：负责需求分析
- 11 架构师Agent：负责系统设计
- 12 开发Agent：负责编写代码
- 13 测试Agent：负责质量保证
- 14 UI设计Agent：负责界面设计
- 15
- 16 → 专业分工
- 17 → 并行工作
- 18 → 质量更高

6.2 多Agent系统架构



6.3 多Agent协作模式

模式1：层级结构（Hierarchical）



特点：

- 有明确的上下级关系
- 管理者负责任务分配和结果整合
- 适合层次清晰的任务

代码实现：

代码块

```

1  from langchain.agents import Agent


```

```

2  from langchain_openai import ChatOpenAI
3
4  class ManagerAgent:
5      def init(self):
6          self.llm = ChatOpenAI(model="gpt-4")
7          self.workers = {
8              "researcher": ResearcherAgent(),
9              "analyst": AnalystAgent(),
10             "writer": WriterAgent(),
11         }
12
13     def delegate(self, task):
14         # 分析任务，分配给合适的worker
15         plan = self.llm.invoke(f"""
16             任务: {task}
17
18             请将任务分解并分配给以下worker:
19             - researcher: 负责搜集信息
20             - analyst: 负责数据分析
21             - writer: 负责内容创作
22
23             输出JSON格式的任务分配:
24             [
25                 {"worker": "researcher", "subtask": "..."},
26                 {"worker": "analyst", "subtask": "..."},
27                 ...
28             ]
29             """)
30
31         # 分配任务
32         results = {}
33         for subtask in plan:
34             worker_name = subtask["worker"]
35             worker = self.workers[worker_name]
36             results[worker_name] =
worker.execute(subtask["subtask"])
37
38         # 整合结果
39         return self.integrate_results(results)
40
41     def integrate_results(self, results):
42         # 让LLM整合各个worker的结果
43         combined = self.llm.invoke(f"""
44             请整合以下各部分的结果:
45
46             研究结果: {results['researcher']}
47             分析结果: {results['analyst']}
48             创作结果: {results['writer']}
49
50             输出最终完整的报告。
51             """)
52         return combined
53
54     # 使用
55     manager = ManagerAgent()
56     result = manager.delegate("分析2024年AI Agent市场趋势并撰写报告")

```

模式2：平等协作（Collaborative）



特点：

- Agents地位平等
- 可以相互协商和讨论
- 适合需要多角度思考的复杂问题

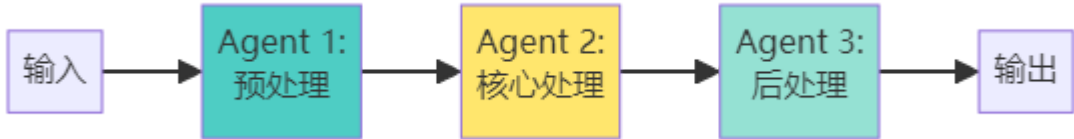
代码实现（AutoGen风格）：

代码块

```
1  from autogen import ConversableAgent
2
3  # 定义三个平等的Agent
4  researcher = ConversableAgent(
5      name="Researcher",
6      system_message="你是一个研究员，负责收集和验证信息。",
7      llm_config={"model": "gpt-4"},
8  )
9
10 critic = ConversableAgent(
11     name="Critic",
12     system_message="你是一个评论家，负责质疑和改进方案。",
13     llm_config={"model": "gpt-4"},
14 )
15
16 writer = ConversableAgent(
17     name="Writer",
18     system_message="你是一个作家，负责组织和表达信息。",
19     llm_config={"model": "gpt-4"},
20 )
21
22 # Agents之间的对话
23 def collaborative_work(task):
24     # Round 1: Researcher提供初步信息
25     research_result = researcher.generate_reply(
26         messages=[{"role": "user", "content": task}]
27     )
28
29     # Round 2: Critic评价和建议
30     critique = critic.generate_reply(
31         messages=[
32             {"role": "user", "content": task},
33             {"role": "assistant", "content": research_result},
34         ]
35     )
36
37     # Round 3: Writer整合并输出
38     final_output = writer.generate_reply(
39         messages=[
40             {"role": "user", "content": task},
41             {"role": "assistant", "content": research_result},
42             {"role": "assistant", "content": critique},
43         ]
44     )
```

```
44     )
45
46     return final_output
47
48 result = collaborative_work("设计一个AI Agent产品的营销策略")
```

模式3：流水线（Pipeline）



特点：

- 固定的处理顺序
- 每个Agent专注于流程中的一个阶段
- 适合有明确步骤的任务

实际案例：内容创作流水线

代码块

```
1  class ContentPipeline:
2      def init(self):
3          self.stages = [
4              ResearchAgent(),      # 阶段1: 研究
5              OutlineAgent(),       # 阶段2: 大纲
6              DraftAgent(),         # 阶段3: 草稿
7              EditorAgent(),        # 阶段4: 编辑
8              SEOAgent(),           # 阶段5: SEO优化
9          ]
10
11     def process(self, topic):
12         data = {"topic": topic}
13
14         for stage in self.stages:
15             print(f"执行阶段: {stage.name}")
16             data = stage.execute(data)
17             print(f"输出: {data[:100]}...\n")
18
19         return data
20
21     # 定义各阶段的Agent
22     class ResearchAgent:
23         name = "Research"
24         def execute(self, data):
25             # 搜索相关资料
26             sources = search(data["topic"])
27             data["sources"] = sources
28             return data
29
30     class OutlineAgent:
31         name = "Outline"
32         def execute(self, data):
33             # 基于sources生成大纲
34             outline = generate_outline(data["sources"])
35             data["outline"] = outline
36             return data
37
38     class DraftAgent:
```

```
39     name = "Draft"
40     def execute(self, data):
41         # 基于outline写草稿
42         draft = write_draft(data["outline"])
43         data["draft"] = draft
44         return data
45
46 class EditorAgent:
47     name = "Editor"
48     def execute(self, data):
49         # 润色和改进草稿
50         edited = edit_content(data["draft"])
51         data["final_content"] = edited
52         return data
53
54 class SEOAgent:
55     name = "SEO"
56     def execute(self, data):
57         # 优化SEO
58         optimized = add_seo_keywords(data["final_content"])
59         data["seo_content"] = optimized
60         return data
61
62 # 使用流水线
63 pipeline = ContentPipeline()
64 article = pipeline.process("AI Agent的商业应用")
```

6.4 多Agent的实战案例

案例：智能软件开发团队

代码块

```
1 class SoftwareDevelopmentTeam:
2     def init(self):
3         # 定义团队成员
4         self.agents = {
5             "pm": ProductManagerAgent(), # 产品经理
6             "architect": ArchitectAgent(), # 架构师
7             "frontend": FrontendAgent(), # 前端开发
8             "backend": BackendAgent(), # 后端开发
9             "tester": TesterAgent(), # 测试工程师
10            "reviewer": CodeReviewerAgent(), # 代码审查
11        }
12
13        self.coordinator = CoordinatorAgent()
14
15    def develop(self, requirement):
16        """完整的开发流程"""
17
18        # 步骤1: 产品经理分析需求
19        print("📋 产品经理分析需求...")
20        prd = self.agents["pm"].analyze_requirement(requirement)
21
22        # 步骤2: 架构师设计系统
23        print("🏗️ 架构师设计系统...")
24        architecture = self.agents["architect"].design_system(prd)
25
26        # 步骤3: 前后端并行开发
27        print("👨‍💻 开发中...")
28        from concurrent.futures import ThreadPoolExecutor
```

Agent直接处理结构化消息，只在必要时…



3月16日 11:08

不理解这部分



7月20日 23:04

直接处理返回的 json 数据，不是文本数据类型，不需要 llm 再次切分理解

```
29
30     with ThreadPoolExecutor(max_workers=2) as executor:
31         frontend_future = executor.submit(
32             self.agents["frontend"].develop,
33             architecture["frontend_spec"]
34         )
35         backend_future = executor.submit(
36             self.agents["backend"].develop,
37             architecture["backend_spec"]
38         )
39
40         frontend_code = frontend_future.result()
41         backend_code = backend_future.result()
42
43     # 步骤4: 代码审查
44     print("🔍 代码审查...")
45     review_result = self.agents["reviewer"].review({
46         "frontend": frontend_code,
47         "backend": backend_code,
48     })
49
50     if not review_result["passed"]:
51         print("⚠️ 代码审查未通过, 需要修改...")
52         # 递归修改, 直到通过
53         return self.develop(requirement) # 简化示例
54
55     # 步骤5: 测试
56     print("🧪 测试中...")
57     test_result = self.agents["tester"].test({
58         "frontend": frontend_code,
59         "backend": backend_code,
60     })
61
62     if not test_result["passed"]:
63         print("❌ 测试失败, 修复bug...")
64         # 修复并重新测试
65         return self.develop(requirement) # 简化示例
66
67     # 步骤6: 部署
68     print("✅ 开发完成! ")
69     return {
70         "prd": prd,
71         "architecture": architecture,
72         "code": {
73             "frontend": frontend_code,
74             "backend": backend_code,
75         },
76         "test_report": test_result,
77     }
78
79 # 使用
80 team = SoftwareDevelopmentTeam()
81 result = team.develop("开发一个AI聊天机器人网站")
82
83 # 输出示例:
84 # 📖 产品经理分析需求...
85 # 🏗️ 架构师设计系统...
86 # 💻 开发中...
87 # 🔍 代码审查...
88 # 🧪 测试中...
```


6.5 多Agent的关键挑战

挑战1：通信开销

多个Agent之间需要频繁通信：

代码块

```
1  #问题：每次通信都要调用LLM
2  Agent1 → LLM → Agent2 → LLM → Agent3
3  成本和延迟都很高
4
5  # 解决：使用结构化消息
6  class Message:
7      def init(self, sender, receiver, content, message_type):
8          self.sender = sender
9          self.receiver = receiver
10         self.content = content  # 结构化数据，不需要LLM理解
11         self.type = message_type  # "task", "result", "question"
12
13     def to_dict(self):
14         return {
15             "from": self.sender,
16             "to": self.receiver,
17             "content": self.content,
18             "type": self.type,
19         }
20
21  # Agent直接处理结构化消息，只在必要时调用LLM
```

| LangChain深度解析



1月7日 06:09 （编辑过）

例子不错

挑战2：死锁和循环依赖

代码块

```
1  #问题：两个Agent互相等待
2  Agent1：等待Agent2的结果...
3  Agent2：等待Agent1的结果...
4  → 死锁
5
6  # 解决：超时和fallback机制
7  class AgentCommunicator:
8      def send_and_wait(self, target_agent, message, timeout=30):
9          start_time = time.time()
10
11         # 发送消息
12         target_agent.receive(message)
13
14         # 等待响应
15         while time.time() - start_time < timeout:
16             if target_agent.has_response():
17                 return target_agent.get_response()
18             time.sleep(0.1)
19
20         # 超时处理
21         return {"error": "Timeout", "fallback": "使用默认值"}
```

挑战3：结果冲突

代码块

```
1  #问题：不同Agent给出不同的答案
2  Agent1: "这个方案可行"
3  Agent2: "这个方案有风险"
4  Agent3: "这个方案成本太高"
5
6  # 解决：投票或仲裁机制
7  class ConflictResolver:
8      def resolve(self, opinions):
9          # 方法1：投票
10         votes = {"agree": 0, "disagree": 0}
11         for opinion in opinions:
12             if opinion["stance"] == "positive":
13                 votes["agree"] += opinion["confidence"]
14             else:
15                 votes["disagree"] += opinion["confidence"]
16
17         if votes["agree"] > votes["disagree"]:
18             return "采纳方案"
19         else:
20             return "否决方案"
21
22         # 方法2：专家仲裁
23         expert = ExpertAgent()
24         final_decision = expert.judge(opinions)
25         return final_decision
```

7. 主流Agent开发框架对比

7.1 框架总览对比

框架	开发商	核心特点	适用场景	学习曲线
LangChain	LangChain Inc	生态最成熟，组件最丰富	通用Agent开发	中等
AutoGen	Microsoft	多Agent协作强大	复杂协作任务	较高
CrewAI	CrewAI	角色扮演，流程化	团队协作模拟	较低
Dify	Dify.ai	可视化编排	快速原型和业务	低
LazyLLM	商汤	懒人友好，中文优化	国内场景	低

7.2 LangChain深度解析

核心概念

代码块

```
1  from langchain.agents import create_react_agent, AgentExecutor
2  from langchain_openai import ChatOpenAI
3  from langchain.tools import Tool
4  from langchain.prompts import PromptTemplate
5
6  # 1. LLM：大脑
7  llm = ChatOpenAI(model="gpt-4", temperature=0)
8
```

```
9  # 2. Tools: 工具
10 tools = [
11     Tool(
12         name="Search",
13         func=search_function,
14         description="搜索互联网信息"
15     ),
16     Tool(
17         name="Calculator",
18         func=calculator_function,
19         description="执行数学计算"
20     ),
21 ]
22
23 # 3. Prompt: 指令模板
24 prompt = PromptTemplate.from_template("""
25 你是一个AI助手。使用以下工具来回答问题：
26  {tools}
27
28 格式：
29  Question: {input}
30  Thought: 思考过程
31  Action: 工具名称
32  Action Input: 工具输入
33  Observation: 工具输出
34  ... (重复)
35  Thought: 我现在知道答案了
36  Final Answer: 最终答案
37
38  Question: {input}
39  {agent_scratchpad}
40  """)
41
42 # 4. Agent: 组装
43 agent = create_react_agent(llm, tools, prompt)
44
45 # 5. Executor: 执行器
46 agent_executor = AgentExecutor(
47     agent=agent,
48     tools=tools,
49     verbose=True,
50     max_iterations=5,
51 )
52
53 # 6. 执行
54 result = agent_executor.invoke({"input": "2024年AI Agent市场规模是多少?"})
```

LangChain的优势

代码块

```
1  #优势1: 丰富的集成
2  from langchain.vectorstores import Chroma
3  from langchain.embeddings import OpenAIEmbeddings
4  from langchain.text_splitter import RecursiveCharacterTextSplitter
5  from langchain.document_loaders import WebBaseLoader
6
7  #一站式RAG方案
8  loader = WebBaseLoader("https://example.com/article")
9  documents = loader.load()
```

```
10
11 text_splitter = RecursiveCharacterTextSplitter(chunk_size=1000)
12 chunks = text_splitter.split_documents(documents)
13
14 vectorstore = Chroma.from_documents(
15     documents=chunks,
16     embedding=OpenAIEmbeddings()
17 )
18
19 #优势2: 灵活的链式组合
20 from langchain.chains import LLMChain
21
22 chain = (
23     prompt
24     | llm
25     | output_parser
26 )
27
28 #优势3: 强大的记忆管理
29 from langchain.memory import ConversationBufferWindowMemory
30
31 memory = ConversationBufferWindowMemory(k=5) # 保留最近5轮对话
```

7.3 AutoGen多Agent协作

AutoGen的特色

代码块

```
1 from autogen import ConversableAgent, GroupChat, GroupChatManager
2
3 #定义多个Agent
4 product_manager = ConversableAgent(
5     name="PM",
6     system_message="你是产品经理，负责需求分析和产品规划。",
7     llm_config={"model": "gpt-4"},
8 )
9
10 engineer = ConversableAgent(
11     name="Engineer",
12     system_message="你是工程师，负责技术实现。",
13     llm_config={"model": "gpt-4"},
14 )
15
16 designer = ConversableAgent(
17     name="Designer",
18     system_message="你是设计师，负责UI/UX设计。",
19     llm_config={"model": "gpt-4"},
20 )
21
22 #创建群聊
23 group_chat = GroupChat(
24     agents=[product_manager, engineer, designer],
25     messages=[],
26     max_round=10,
27 )
28
29 #管理者
30 manager = GroupChatManager(
31     groupchat=group_chat,
32     llm_config={"model": "gpt-4"},
```

```
33 )
34
35 #开始协作
36 product_manager.initiate_chat(
37     manager,
38     message="我们需要开发一个AI聊天应用，大家讨论一下方案。",
39 )
40
41 #输出示例：
42 #PM: "我建议使用WebSocket实现实时通信..."
43 #Engineer: "技术上可行，我可以用FastAPI+WebSocket实现..."
44 #Designer: "UI应该简洁，参考Slack的设计..."
45 #PM: "同意，我们先做MVP..."
46 #...
```

AutoGen的并行执行

代码块

```
1  #多个Agent同时工作
2  from autogen import UserProxyAgent
3
4  user_proxy = UserProxyAgent(
5      name="User",
6      human_input_mode="NEVER", # 不需要人工输入
7      code_execution_config={"work_dir": "workspace"},
8  )
9
10 #并行任务
11 tasks = [
12     "搜索2024年AI发展趋势",
13     "分析主要竞争对手",
14     "设计产品架构",
15 ]
16
17 import asyncio
18
19 async def parallel_execution():
20     results = await asyncio.gather(*[
21         agent.a_generate_reply({"content": task})
22         for task in tasks
23     ])
24     return results
```

7.4 CrewAI角色扮演框架

CrewAI的团队概念

代码块

```
1  from crewai import Agent, Task, Crew
2
3  #定义角色
4  researcher = Agent(
5      role="Research Analyst",
6      goal="发现AI Agent领域的最新趋势",
7      backstory="你是一个经验丰富的AI研究分析师...",
8      tools=[search_tool],
9      verbose=True,
10 )
```

```
11
12 writer = Agent(
13     role="Content Writer",
14     goal="撰写吸引人的技术文章",
15     backstory="你是一个技术作家，擅长将复杂概念简化...",
16     tools=[],
17     verbose=True,
18 )
19
20 #定义任务
21 task1 = Task(
22     description="研究2024年AI Agent的市场趋势",
23     agent=researcher,
24     expected_output="详细的市场分析报告",
25 )
26
27 task2 = Task(
28     description="基于研究结果撰写一篇博客文章",
29     agent=writer,
30     expected_output="1500字的博客文章",
31 )
32
33 #组建团队
34 crew = Crew(
35     agents=[researcher, writer],
36     tasks=[task1, task2],
37     verbose=True,
38     process="sequential", # 顺序执行
39 )
40
41 #启动
42 result = crew.kickoff()
```

7.5 Dify可视化平台

Dify的工作流编排

代码块

```
1  [用户输入]
2      ↓
3  [LLM节点：理解意图]
4      ↓
5  [条件分支]
6      └─ 需要搜索 → [搜索节点] → [LLM节点：总结]
7      └─ 不需要搜索 → [LLM节点：直接回答]
8      ↓
9  [输出节点]
```

Dify的优势：

- ✔ 拖拽式设计，无需代码
- ✔ 内置RAG、Agent、工作流模板
- ✔ 可视化调试和监控
- ✔ 一键部署API

适用场景：

- 快速原型验证

- 业务人员使用
- 低代码场景

7.6 框架选择指南

代码块

```
1 def choose_framework(scenario):
2     if scenario == "学习和探索":
3         return "LangChain - 生态最完善，教程最多"
4     elif scenario == "多Agent协作":
5         return "AutoGen - 专为多Agent设计"
6     elif scenario == "团队流程模拟":
7         return "CrewAI - 角色扮演最自然"
8     elif scenario == "快速原型":
9         return "Dify - 可视化，上手快"
10    elif scenario == "国内部署":
11        return "LazyLLM - 中文优化，商汤支持"
12    elif scenario == "生产级应用":
13        return "LangChain + 自定义优化"
14    else:
15        return "LangChain - 最保险的选择"
```

8. Agent实战案例与代码实现

8.1 案例一：智能客服Agent

需求分析

代码块

```
1  场景：电商平台的客服系统
2
3  功能要求：
4  回答常见问题（FAQ）
5  查询订单状态
6  处理退换货
7  转人工客服（复杂问题）
8  技术挑战：
9  需要访问数据库（订单系统）
10 需要记忆上下文（多轮对话）
11 需要情感识别（判断用户情绪）
```

完整实现

代码块

```
1 from langchain.agents import create_react_agent, AgentExecutor
2 from langchain_openai import ChatOpenAI
3 from langchain.tools import Tool
4 from langchain.memory import ConversationBufferMemory
5 import sqlite3
6
7 # 1. 定义工具
8
9 def query_order(order_id: str) -> str:
10     """查询订单状态"""
```

```
11     conn = sqlite3.connect('ecommerce.db')
12     cursor = conn.cursor()
13
14     cursor.execute(
15         "SELECT status, items, total FROM orders WHERE order_id =
16         ?",
17         (order_id,)
18     )
19     result = cursor.fetchone()
20     conn.close()
21
22     if result:
23         status, items, total = result
24         return f"订单状态: {status}, 商品: {items}, 总金额: {total}元"
25     else:
26         return "未找到该订单"
27
28 def search_faq(question: str) -> str:
29     """搜索FAQ知识库"""
30     faq_db = {
31         "退货": "退货政策: 7天无理由退货, 商品需保持完好...",
32         "发货": "发货时间: 工作日下单当天发货, 节假日顺延...",
33         "支付": "支付方式: 支持微信、支付宝、信用卡...",
34     }
35     # 简单的关键词匹配
36     for key, answer in faq_db.items():
37         if key in question:
38             return answer
39
40     return "未找到相关FAQ, 建议转人工客服"
41
42 def detect_emotion(text: str) -> str:
43     """检测用户情绪"""
44     negative_words = ["生气", "不满意", "糟糕", "差", "垃圾"]
45
46     for word in negative_words:
47         if word in text:
48             return "negative"
49
50     return "neutral"
51
52 # 2. 创建工具列表
53
54 tools = [
55     Tool(
56         name="QueryOrder",
57         func=query_order,
58         description="查询订单状态。输入订单号, 返回订单详情。"
59     ),
60     Tool(
61         name="SearchFAQ",
62         func=search_faq,
63         description="搜索常见问题答案。输入问题关键词。"
64     ),
65     Tool(
66         name="DetectEmotion",
67         func=detect_emotion,
68         description="检测用户情绪。输入用户消息文本。"
69     ),
70 ]
71
```



```
72  # 3. 创建客服Agent
73
74  llm = ChatOpenAI(model="gpt-4", temperature=0.7)
75
76  memory = ConversationBufferMemory(
77      memory_key="chat_history",
78      return_messages=True
79  )
80
81  customer_service_prompt = """
82  你是一个友好、专业的电商客服AI助手。
83
84  你的职责：
85  1. 热情回答用户问题
86  2. 查询订单信息
87  3. 处理退换货问题
88  4. 如遇复杂问题，建议转人工客服
89
90  重要原则：
91  - 始终保持礼貌和耐心
92  - 如果用户情绪不好，先安抚情绪
93  - 准确查询信息，不要编造数据
94  - 不确定时建议转人工
95
96  可用工具：
97  {tools}
98
99  对话历史：
100 {chat_history}
101
102  用户问题：{input}
103  {agent_scratchpad}
104  """
105
106  agent = create_react_agent(llm, tools, customer_service_prompt)
107
108  agent_executor = AgentExecutor(
109      agent=agent,
110      tools=tools,
111      memory=memory,
112      verbose=True,
113      max_iterations=5,
114  )
115
116  # 4. 使用示例
117
118  def chat_with_customer(user_input):
119      result = agent_executor.invoke({"input": user_input})
120      return result["output"]
121
122  # 对话流程
123  print("客服：您好！我是AI客服小助手，很高兴为您服务~")
124
125  # 第一轮
126  user1 = "我想查一下订单号12345的状态"
127  response1 = chat_with_customer(user1)
128  print(f"客服：{response1}")
129
130  # Agent思考过程（verbose=True会显示）：
131  # Thought: 用户想查询订单，我需要使用QueryOrder工具
132  # Action: QueryOrder
133  # Action Input: "12345"
```



```
134 # Observation: 订单状态：已发货，商品：iPhone 15，总金额：5999元
135 # Thought: 我现在知道订单信息了
136 # Final Answer: 您的订单12345已经发货啦! ...
137
138 # 第二轮（记忆上下文）
139 user2 = "什么时候能到？"
140 response2 = chat_with_customer(user2)
141 print(f"客服: {response2}")
142
143 # Agent会记得在讨论订单12345
```

增强版：处理情绪和转人工

代码块

```
1 class EnhancedCustomerServiceAgent:
2     def __init__(self):
3         self.agent = agent_executor
4         self.human_agent_queue = []
5     def handle_message(self, user_input):
6         # 1. 检测情绪
7         emotion = detect_emotion(user_input)
8         if emotion == "negative":
9             # 情绪不好，优先安抚
10            comfort_msg = "非常抱歉给您带来不好的体验，我会尽快帮您解决问
11            题..."
12            print(f"客服: {comfort_msg}")
13            # 2. Agent处理
14            try:
15                response = self.agent.invoke({"input": user_input})
16                result = response["output"]
17                # 3. 判断是否需要转人工
18                if self._need_human_agent(result):
19                    return self._transfer_to_human(user_input)
20                return result
21            except Exception as e:
22                # 出错时转人工
23                return self._transfer_to_human(user_input)
24    def _need_human_agent(self, agent_response):
25        # 检测关键词
26        keywords = ["转人工", "不能解决", "复杂问题"]
27        return any(kw in agent_response for kw in keywords)
28    def _transfer_to_human(self, user_input):
29        self.human_agent_queue.append({
30            "user_input": user_input,
31            "timestamp": datetime.now(),
32        })
33        return "我为您转接人工客服，请稍等..."
34
35 #使用
36 enhanced_agent = EnhancedCustomerServiceAgent()
37 response = enhanced_agent.handle_message("我的订单有问题，很生气！")
```

8.2 案例二：代码生成Agent

需求分析

代码块

```
1 功能：根据自然语言描述生成代码
```

```
2
3 流程：
4     理解需求
5     设计方案
6     生成代码
7     测试代码
8     修复bug（如果有）
9     添加注释和文档
```

实现

代码块

```
1  from langchain.agents import Tool
2  import subprocess
3  import tempfile
4  import os
5
6  class CodeGenerationAgent:
7      def init(self):
8          self.llm = ChatOpenAI(model="gpt-4", temperature=0)
9
10         # 定义工具
11         self.tools = [
12             Tool(
13                 name="GenerateCode",
14                 func=self._generate_code,
15                 description="生成Python代码"
16             ),
17             Tool(
18                 name="TestCode",
19                 func=self._test_code,
20                 description="测试代码是否可以运行"
21             ),
22             Tool(
23                 name="FixBug",
24                 func=self._fix_bug,
25                 description="修复代码中的bug"
26             ),
27         ]
28
29     def _generate_code(self, requirement: str) -> str:
30         """生成代码"""
31         prompt = f"""
32         请根据以下需求生成Python代码：
33
34         需求：{requirement}
35
36         要求：
37         1. 代码要清晰、可读
38         2. 添加必要的注释
39         3. 包含错误处理
40         4. 包含使用示例
41
42         请输出完整的可运行代码。
43         """
44
45         response = self.llm.invoke(prompt)
46         code = self._extract_code(response.content)
47         return code
48
```

```

49     def _test_code(self, code: str) -> dict:
50         """测试代码"""
51         # 创建临时文件
52         with tempfile.NamedTemporaryFile(
53             mode='w',
54             suffix='.py',
55             delete=False
56         ) as f:
57             f.write(code)
58             temp_file = f.name
59
60         try:
61             # 运行代码
62             result = subprocess.run(
63                 ['python', temp_file],
64                 capture_output=True,
65                 text=True,
66                 timeout=5
67             )
68
69             if result.returncode == 0:
70                 return {
71                     "success": True,
72                     "output": result.stdout,
73                 }
74             else:
75                 return {
76                     "success": False,
77                     "error": result.stderr,
78                 }
79
80         except subprocess.TimeoutExpired:
81             return {
82                 "success": False,
83                 "error": "代码执行超时"
84             }
85
86         finally:
87             os.unlink(temp_file)
88
89     def _fix_bug(self, code: str, error: str) -> str:
90         """修复bug"""
91         prompt = f"""
92         以下代码有错误：
93
94         代码：
95         ```python
96         {code}
97         ```
98
99         错误信息：
100        {error}
101
102        请修复这个bug并返回完整的正确代码。
103        """
104
105        response = self.llm.invoke(prompt)
106        fixed_code = self._extract_code(response.content)
107        return fixed_code
108
109     def _extract_code(self, text: str) -> str:
110         """从回复中提取代码"""

```

```
111         # 提取``python...``之间的内容
112         import re
113         pattern = r"``python\n(.*)``"
114         match = re.search(pattern, text, re.DOTALL)
115
116         if match:
117             return match.group(1).strip()
118         else:
119             return text.strip()
120
121     def generate(self, requirement: str, max_attempts=3):
122         """完整的代码生成流程"""
123         print(f"📝 需求: {requirement}\n")
124
125         # 步骤1: 生成代码
126         print("1️⃣ 生成代码...")
127         code = self._generate_code(requirement)
128         print(f"生成的代码: \n{code}\n")
129
130         # 步骤2: 测试代码
131         print("2️⃣ 测试代码...")
132
133         for attempt in range(max_attempts):
134             test_result = self._test_code(code)
135
136             if test_result["success"]:
137                 print("✅ 测试通过! ")
138                 print(f"输出: {test_result['output']}")
139
140                 # 步骤3: 添加文档
141                 print("\n3️⃣ 添加文档...")
142                 documented_code = self._add_documentation(code)
143
144                 return documented_code
145
146             else:
147                 print(f"❌ 测试失败 (尝试 {attempt+1}/{max_attempts}) ")
148                 print(f"错误: {test_result['error']}\n")
149
150                 # 修复bug
151                 print("🔧 修复bug...")
152                 code = self._fix_bug(code, test_result['error'])
153                 print(f"修复后的代码: \n{code}\n")
154
155         # 所有尝试都失败
156         return {
157             "success": False,
158             "message": f"经过{max_attempts}次尝试仍无法生成可运行的代
码",
159             "last_code": code,
160         }
161
162     def _add_documentation(self, code: str) -> str:
163         """添加文档字符串"""
164         prompt = f"""
165         为以下代码添加详细的文档字符串（docstring）和使用说明：
166
167         ```python
168         {code}
169         ```
170
```

```
171         要求：
172         1. 每个函数都有docstring
173         2. 包含参数说明
174         3. 包含返回值说明
175         4. 包含使用示例
176         """
177
178         response = self.llm.invoke(prompt)
179         return self._extract_code(response.content)
180
181     # 使用示例
182     agent = CodeGenerationAgent()
183
184     result = agent.generate("""
185     写一个函数，计算列表中所有数字的平方和。
186     要求：
187     - 输入是一个数字列表
188     - 返回平方和
189     - 包含错误处理（如果输入不是数字）
190     """)
191
192     print("\n" + "="*50)
193     print("最终代码：")
194     print("="*50)
195     print(result)
196
197     # 输出示例：
198     # 📝 需求：写一个函数，计算列表中所有数字的平方和...
199     #
200     # 1️⃣ 生成代码...
201     # 生成的代码：
202     # def sum_of_squares(numbers):
203     #     total = 0
204     #     for num in numbers:
205     #         total += num ** 2
206     #     return total
207     #
208     # 2️⃣ 测试代码...
209     # ✅ 测试通过！
210     #
211     # 3️⃣ 添加文档...
212     #
213     # =====
214     # 最终代码：
215     # =====
216     # def sum_of_squares(numbers):
217     #     """
218     #     计算列表中所有数字的平方和。
219     #
220     #     参数：
221     #         numbers (list): 数字列表
222     #
223     #     返回：
224     #         int/float: 所有数字的平方和
225     #
226     #     示例：
227     #         >>> sum_of_squares([1, 2, 3])
228     #         14
229     #     """
230     #     ...
```

8.3 案例三：数据分析Agent

需求

代码块

- 1
- 场景：自动分析Excel数据
- 2
- 3
- 功能：
- 4
- 读取Excel文件
- 5
- 数据清洗和预处理
- 6
- 统计分析（均值、中位数等）
- 7
- 生成可视化图表
- 8
- 输出分析报告

实现（完整代码过长，展示关键部分）

代码块

```
1  import pandas as pd
2  import matplotlib.pyplot as plt
3
4  class DataAnalysisAgent:
5      def analyze(self, file_path: str, question: str):
6          """
7              分析数据并回答问题
8              参数：
9                  file_path: Excel文件路径
10                 question: 分析问题
11          """
12          # 1. 读取数据
13          print("📂 读取数据...")
14          df = pd.read_excel(file_path)
15          print(f"数据形状: {df.shape}")
16          print(f"列名: {df.columns.tolist()}\n")
17          # 2. 让Agent分析应该做什么
18          print("🤖 分析问题...")
19          analysis_plan = self._plan_analysis(df, question)
20          print(f"分析计划: \n{analysis_plan}\n")
21          # 3. 执行分析
22          print("⚙️ 执行分析...")
23          results = self._execute_analysis(df, analysis_plan)
24          # 4. 生成报告
25          print("📝 生成报告...")
26          report = self._generate_report(results, question)
27          return report
28
29      def _plan_analysis(self, df, question):
30          """制定分析计划"""
31          prompt = f"""
32          数据集信息：
33          - 形状: {df.shape}
34          - 列名: {df.columns.tolist()}
35          - 前5行数据:
36            {df.head().to_string()}
37          问题: {question}
38          请制定分析计划（JSON格式）：
39          {{
40              "steps": [
41                  {{ "action": "统计描述", "columns": ["..."] }},
42                  {{ "action": "分组分析", "group_by": "...", "agg":
```

```
42         {"action": "可视化", "chart_type": "...", "x":
    "...", "y": "..."}}
43     ]
44     }}
45     """
46     response = self.llm.invoke(prompt)
47     return json.loads(response.content)
48     def _execute_analysis(self, df, plan):
49         """执行分析步骤"""
50         results = {}
51         for step in plan["steps"]:
52             action = step["action"]
53             if action == "统计描述":
54                 results["统计"] = df[step["columns"]].describe()
55             elif action == "分组分析":
56                 results["分组"] =
df.groupby(step["group_by"]).agg(step["agg"])
57             elif action == "可视化":
58                 self._create_chart(df, step)
59                 results["图表"] = "已生成"
60         return results
61
62     #使用
63     agent = DataAnalysisAgent()
64     report = agent.analyze(
65         "sales_data.xlsx",
66         "分析各地区的销售情况，找出销售最好的3个地区"
67     )
```

9. Agent性能优化与最佳实践

9.1 提示词工程优化

技巧1：Few-Shot Examples

代码块

```
1     #❌ 不好的提示词
2     prompt = "请分析这段代码"
3
4     #✅ 好的提示词（包含示例）
5     prompt = """
6     请分析代码的时间复杂度。
7
8     示例1：
9     代码：
10    for i in range(n):
11        print(i)
12
13    分析：时间复杂度 O(n)，因为循环执行n次。
14
15    示例2：
16    代码：
17    for i in range(n):
18        for j in range(n):
19            print(i, j)
20
21    分析：时间复杂度 O(n²)，因为嵌套循环执行n*n次。
```



```
22
23 现在请分析以下代码：
24 {code}
25 """
```

技巧2: Chain of Thought

代码块

```
1  #❌ 直接要求答案
2  prompt = "2024年哪个国家GDP最高？"
3
4  #✅ 引导逐步思考
5  prompt = """
6  请回答：2024年哪个国家GDP最高？
7
8  请按以下步骤思考：
9  1. 首先，我需要搜索2024年全球GDP排名
10 2. 然后，找到排名第一的国家
11 3. 最后，验证这个信息的可靠性
12
13 现在开始：
14 """
```

技巧3: 角色扮演

代码块

```
1  #❌ 通用指令
2  prompt = "帮我写代码"
3
4  #✅ 明确角色
5  prompt = """
6  你是一个资深的Python工程师，有10年开发经验。
7  你的代码特点：
8  清晰易读
9  注重性能
10 考虑边界情况
11 包含完整的错误处理
12 现在请帮我写一个函数...
13 """
```

9.2 工具调用优化

优化1: 工具描述标准化

代码块

```
1  class ToolDescriptionTemplate:
2      """标准化的工具描述模板"""
3      @staticmethod
4      def create_description(
5          purpose: str,
6          input_format: str,
7          output_format: str,
8          use_cases: list,
9          limitations: list,
10     ):
11         return f"""
```



```

12  工具目的: {purpose}
13
14  输入格式: {input_format}
15  输出格式: {output_format}
16
17  适用场景:
18  {chr(10)}.join(f"- {case}" for case in use_cases)}
19
20  不适用场景:
21  {chr(10)}.join(f"- {limit}" for limit in limitations)}
22
23  示例:
24  输入: "example_input"
25  输出: "example_output"
26  ""
27
28  使用
29  search_tool_desc = ToolDescriptionTemplate.create_description(
30      purpose="搜索互联网获取最新信息",
31      input_format="字符串 (搜索查询) ",
32      output_format="字符串 (搜索结果摘要) ",
33      use_cases=[
34          "需要最新数据 (新闻、事件) ",
35          "查找具体信息 (人物、地点) ",
36          "验证事实",
37      ],
38      limitations=[
39          "不用于数学计算",
40          "不用于代码执行",
41          "不用于个人隐私信息",
42      ],
43  )

```

优化2: 工具调用缓存

代码块

```

1  from functools import lru_cache
2  import hashlib
3
4  class CachedToolExecutor:
5      def init(self):
6          self.cache = {}
7          self.cache_hits = 0
8          self.cache_misses = 0
9
10     def execute(self, tool_name: str, tool_input: str):
11         # 生成缓存key
12         cache_key = hashlib.md5(
13             f"{tool_name}:{tool_input}".encode()
14         ).hexdigest()
15
16         # 检查缓存
17         if cache_key in self.cache:
18             self.cache_hits += 1
19             print(f"✅ Cache hit! (命中率: {self.hit_rate:.2%})")
20             return self.cache[cache_key]
21
22         # 执行工具
23         self.cache_misses += 1
24         result = self._actual_execute(tool_name, tool_input)

```

```

25
26         # 存入缓存
27         self.cache[cache_key] = result
28         return result
29
30     @property
31     def hit_rate(self):
32         total = self.cache_hits + self.cache_misses
33         return self.cache_hits / total if total > 0 else 0

```

9.3 成本优化策略

策略1：智能Token管理

代码块

```

1  class TokenOptimizer:
2      def __init__(self, max_tokens=4000):
3          self.max_tokens = max_tokens
4      def compress_context(self, messages: list) -> list:
5          """压缩上下文"""
6          total_tokens = sum(len(m["content"]).split()) for m in
messages)
7          if total_tokens <= self.max_tokens:
8              return messages
9          # 保留最近的和最重要的
10         recent_messages = messages[-3:] # 最近3条
11         important_messages = self._extract_important(messages[:-3])
12         return important_messages + recent_messages
13     def _extract_important(self, messages):
14         """提取重要消息"""
15         # 使用关键词识别重要性
16         important_keywords = ["重要", "关键", "必须", "注意"]
17         important = []
18         for msg in messages:
19             if any(kw in msg["content"] for kw in
important_keywords):
20                 important.append(msg)
21         return important[:2] # 最多保留2条

```

策略2：批量处理

代码块

```

1  def batch_process_with_cost_tracking(tasks, batch_size=10):
2      """批量处理并跟踪成本"""
3      results = []
4      total_cost = 0
5
6      for i in range(0, len(tasks), batch_size):
7          batch = tasks[i:i+batch_size]
8
9          # 批量处理
10         batch_prompt = create_batch_prompt(batch)
11         response = llm.invoke(batch_prompt)
12
13         # 计算成本
14         tokens_used = count_tokens(batch_prompt) +
count_tokens(response.content)
15         batch_cost = calculate_cost(tokens_used)

```

```

16         total_cost += batch_cost
17
18         print(f"批次{i//batch_size + 1}: {len(batch)}个任务, 成本
19         ${batch_cost:.4f}")
20
21         # 解析结果
22         batch_results = parse_batch_response(response.content)
23         results.extend(batch_results)
24
25         print(f"\n总成本: ${total_cost:.4f}")
26         print(f"平均每任务: ${total_cost/len(tasks):.4f}")
27
28         return results

```

9.4 可靠性增强

技巧1：重试机制

代码块

```

1  import time
2  from functools import wraps
3
4  def retry_with_exponential_backoff(
5      max_retries=3,
6      initial_delay=1,
7      exponential_base=2,
8  ):
9      """指数退避重试装饰器"""
10     def decorator(func):
11         @wraps(func)
12         def wrapper(*args, **kwargs):
13             delay = initial_delay
14
15             for attempt in range(max_retries):
16                 try:
17                     return func(*args, **kwargs)
18                 except Exception as e:
19                     if attempt == max_retries - 1:
20                         raise
21
22                     print(f"⚠️ 尝试{attempt+1}失败: {e}")
23                     print(f"等待{delay}秒后重试...")
24                     time.sleep(delay)
25                     delay *= exponential_base
26
27             return wrapper
28     return decorator
29
30     # 使用
31     @retry_with_exponential_backoff(max_retries=3)
32     def call_llm(prompt):
33         return llm.invoke(prompt)

```

技巧2：健康检查

代码块

```

1  class AgentHealthMonitor:
2      def init(self):

```

```

3         self.metrics = {
4             "total_requests": 0,
5             "successful_requests": 0,
6             "failed_requests": 0,
7             "total_latency": 0,
8         }
9
10    def record_request(self, success: bool, latency: float):
11        self.metrics["total_requests"] += 1
12        self.metrics["total_latency"] += latency
13
14        if success:
15            self.metrics["successful_requests"] += 1
16        else:
17            self.metrics["failed_requests"] += 1
18
19    def get_health_status(self):
20        total = self.metrics["total_requests"]
21        if total == 0:
22            return "UNKNOWN"
23
24        success_rate = self.metrics["successful_requests"] / total
25        avg_latency = self.metrics["total_latency"] / total
26
27        if success_rate >= 0.95 and avg_latency < 2:
28            return "HEALTHY"
29        elif success_rate >= 0.8:
30            return "DEGRADED"
31        else:
32            return "UNHEALTHY"
33
34    def get_report(self):
35        total = self.metrics["total_requests"]
36        if total == 0:
37            return "暂无数据"
38
39        return f"""
40    健康状态: {self.get_health_status()}
41
42    统计信息:
43    - 总请求数: {total}
44    - 成功率: {self.metrics["successful_requests"]/total:.2%}
45    - 平均延迟: {self.metrics["total_latency"]/total:.2f}秒
46    """

```

9.5 调试与监控

调试技巧

代码块

```

1    class DebugAgent:
2        def init(self, agent, debug_mode=True):
3            self.agent = agent
4            self.debug_mode = debug_mode
5            self.execution_log = []
6
7        def execute(self, task):
8            if self.debug_mode:
9                print("\n" + "="*50)
10               print("🔍 调试模式")

```

```
11         print("="*50)
12         print(f"任务: {task}\n")
13
14         start_time = time.time()
15
16         try:
17             # 记录每一步
18             result = self._execute_with_logging(task)
19
20             if self.debug_mode:
21                 self._print_execution_summary(time.time() -
start_time)
22
23             return result
24
25         except Exception as e:
26             if self.debug_mode:
27                 self._print_error_details(e)
28             raise
29
30     def _execute_with_logging(self, task):
31         # 钩子: 记录每次工具调用
32         original_tool_call = self.agent.tool_executor.call
33
34         def logged_tool_call(tool_name, tool_input):
35             self.execution_log.append({
36                 "type": "tool_call",
37                 "tool": tool_name,
38                 "input": tool_input,
39                 "timestamp": time.time(),
40             })
41
42             result = original_tool_call(tool_name, tool_input)
43
44             self.execution_log.append({
45                 "type": "tool_result",
46                 "tool": tool_name,
47                 "result": result,
48                 "timestamp": time.time(),
49             })
50
51             if self.debug_mode:
52                 print(f"\n🔧 工具调用: {tool_name}")
53                 print(f"输入: {tool_input}")
54                 print(f"输出: {result[:100]}...")
55
56             return result
57
58         self.agent.tool_executor.call = logged_tool_call
59
60         return self.agent.execute(task)
61
62     def _print_execution_summary(self, duration):
63         print("\n" + "="*50)
64         print("📊 执行总结")
65         print("="*50)
66         print(f"总耗时: {duration:.2f}秒")
67         print(f"工具调用次数: {len([l for l in self.execution_log if
l['type']=='tool_call'])}")
68         print(f"执行步骤: {len(self.execution_log)}")
```

10. 未来展望：Agent的发展趋势

10.1 技术趋势

趋势1：更强的推理能力

代码块

- 当前（2024）：
 - GPT-4：擅长语言理解和生成
 - 推理能力有限（复杂数学、逻辑）
- 未来（2025-2026）：
 - OpenAI o1系列：专注推理
 - DeepSeek-R1：强化学习推理
 - 推理时间↑，推理准确度↑

影响：

- Agent可以处理更复杂的任务
- 减少对外部工具的依赖
- 更少的错误和幻觉

趋势2：多模态Agent

代码块

- 当前：主要处理文本
- 未来：
 - 图像理解（识别图表、设计UI）
 - 视频分析（剪辑、内容审核）
 - 语音交互（实时对话）
 - 3D环境操作（游戏、仿真）

示例场景：

代码块

- 用户上传设计草图 → Agent识别 → 生成HTML/CSS → 自动部署网站

趋势3：个性化和记忆增强

代码块

- 当前：对话级记忆
- 未来：
 - 跨会话的长期记忆
 - 个性化学习（理解用户习惯）
 - 主动建议（不等用户询问）

补充



🎯 第一章：什么是意图识别？一个生活化的例子

1.1 从咖啡店点单说起

🔥 想象你走进一家咖啡店，对服务员说："好冷啊，来点热的。"

服务员会怎么做？她不会傻乎乎地问"你到底要什么"，而是立刻明白：

- **表面话语**："好冷啊，来点热的"
- **真实意图**：我想要一杯热饮

这就是**意图识别**！

1.2 AI Agent中的意图识别

意图识别工作流程



常见意图示例

用户说

识别意图

"帮我订张机票"

→ 预订机票

"我的订单到哪了?"

→ 查询订单

"太贵了有便宜的吗?"

→ 价格筛选

在AI世界里，意图识别（Intent Recognition）就是让机器理解用户说话背后的真实目的。

举个例子：

用户说的话	AI识别的意图	应该做什么
"今天天气怎么样？"	查询天气	调用天气API
"帮我订张去北京的机票"	预订机票	打开订票流程
"我的订单到哪了？"	查询订单	查询物流信息
"太贵了，有便宜点的吗？"	价格筛选	推荐低价商品

配图说明：参见 `intent_recognition_flow.svg`

1.3 为什么意图识别这么重要？

没有意图识别的AI就像：

- 只会死板回答的机器人
- 听不懂人话的客服
- 需要你说精确命令的语音助手

有了意图识别的AI就像：

- 能读懂你心思的贴心助手
- 聪明的问题解决专家
- 精准响应的智能系统

第二章：AI Agent的"读心术"：意图识别的魔法原理

2.1 意图识别的三层结构

意图识别不是一步到位的，而是分为三个层次：



第一层：文本理解（Text Understanding）

把用户说的话变成机器能理解的形式。

例子：

代码块

```
1  用户输入："我想买一台笔记本电脑，预算5000左右"
2  ↓ 文本理解
3  结构化数据：
4  {
5      "动作": "购买",
6      "商品类别": "笔记本电脑",
7      "预算": 5000,
8      "单位": "元"
9  }
```

第二层：意图分类（Intent Classification）

判断用户想做什么事情。

例子：

代码块

```
1  输入："这款手机有货吗？"
2  → 意图分类 → 库存查询
3
4  输入："帮我退货"
5  → 意图分类 → 退款申请
6
```

7 输入: "客服在吗?"
8 → 意图分类 → 人工服务

第三层：槽位填充（Slot Filling）

提取关键信息，填补意图执行所需的参数。

例子：

代码块

```
1 意图：预订酒店
2 必需槽位：
3   - 城市：？
4   - 入住日期：？
5   - 退房日期：？
6   - 房间数量：？
7
8 用户说："下周去上海住两晚"
9 提取结果：
10  - 城市：上海 ✓
11  - 入住日期：下周一 ✓
12  - 退房日期：下周三 ✓
13  - 房间数量：未知 ✗ → 需要追问
```

2.2 意图识别的工作流程

配图说明：参见 `workflow.svg`

完整流程如下：

代码块

```
1 1. 用户输入 → 2. 文本预处理 → 3. 特征提取 → 4. 意图分类
2                                     ↓
3 7. 执行动作 ← 6. 槽位验证 ← 5. 槽位填充 ← [意图+槽位]
```

具体步骤解释：

1. 用户输入：接收原始文本
2. 文本预处理：去除标点、统一大小写、分词
3. 特征提取：将文本转为向量（数字表示）
4. 意图分类：用模型预测意图类别
5. 槽位填充：提取关键信息
6. 槽位验证：检查必需信息是否完整
7. 执行动作：调用对应的功能模块

第三章：三大核心技术：让AI懂你所想

3.1 技术一：基于规则的意图识别（规则匹配）

原理

用预定义的关键词和模式来匹配用户意图。

优点

-  简单易懂
-  可控性强
-  适合固定场景

缺点

-  覆盖面窄
-  难以处理复杂语句
-  维护成本高

代码示例

代码块

```
1  class RuleBasedIntentRecognizer:
2      def __init__(self):
3          # 定义意图规则字典
4          self.intent_rules = {
5              "查询天气": ["天气", "温度", "下雨", "晴天", "气温"],
6              "订票": ["订票", "买票", "机票", "车票", "预订"],
7              "查询订单": ["订单", "物流", "快递", "到哪了", "发货"],
8              "退款": ["退款", "退货", "不想要", "退钱"],
9              "人工客服": ["人工", "客服", "转人工", "找客服"]
10         }
11
12     def recognize(self, text):
13         """识别意图"""
14         text = text.lower() # 转小写
15
16         # 遍历所有意图规则
17         for intent, keywords in self.intent_rules.items():
18             # 检查是否包含关键词
19             for keyword in keywords:
20                 if keyword in text:
21                     return {
22                         "intent": intent,
23                         "confidence": 0.9, # 规则匹配给固定置信度
24                         "matched_keyword": keyword
25                     }
26
27         # 没有匹配到任何规则
28         return {
29             "intent": "未知意图",
30             "confidence": 0.0,
31             "matched_keyword": None
32         }
33
34     # 使用示例
35     recognizer = RuleBasedIntentRecognizer()
36
37     # 测试
38     test_cases = [
39         "今天天气怎么样？",
40         "帮我订张机票",
41         "我的快递到哪了？",
42         "想退货",
43         "转人工客服"
44     ]
45
```

```
46 for text in test_cases:
47     result = recognizer.recognize(text)
48     print(f"输入: {text}")
49     print(f"意图: {result['intent']], 置信度:
{result['confidence']}")
50     print()
```

运行结果：

代码块

```
1  输入：今天天气怎么样？
2  意图：查询天气，置信度：0.9
3
4  输入：帮我订张机票
5  意图：订票，置信度：0.9
6
7  输入：我的快递到哪了？
8  意图：查询订单，置信度：0.9
9
10 输入：想退货
11 意图：退款，置信度：0.9
12
13 输入：转人工客服
14 意图：人工客服，置信度：0.9
```

3.2 技术二：基于机器学习的意图识别

原理

用大量标注数据训练分类模型，让AI自动学习意图识别规律。

机器学习意图识别流程



核心步骤

8. 数据准备

代码块

```
1  # 训练数据示例
2  training_data = [
3      ("今天天气怎么样", "查询天气"),
4      ("北京现在多少度", "查询天气"),
5      ("会下雨吗", "查询天气"),
6      ("帮我订一张机票", "订票"),
7      ("买票去上海", "订票"),
8      ("预订高铁票", "订票"),
9      ("我的订单到哪了", "查询订单"),
10     ("快递什么时候到", "查询订单"),
11 ]
```

9. 特征工程

将文本转为向量：

代码块

```
1  from sklearn.feature_extraction.text import TfidfVectorizer
2
3  # TF-IDF向量化
4  vectorizer = TfidfVectorizer()
5  X = vectorizer.fit_transform([text for text, _ in training_data])
6
7  # 文本 "今天天气怎么样" 会变成向量：
8  # [0.0, 0.5, 0.3, 0.0, 0.7, ...]
9  #   ↑   ↑   ↑   ↑   ↑
10  # 词1 词2 词3 词4 词5
```

10. 模型训练

代码块

```
1  from sklearn.naive_bayes import MultinomialNB
2
3  # 朴素贝叶斯分类器
4  classifier = MultinomialNB()
5  classifier.fit(X, labels)
```

完整代码实现

代码块

```
1  import jieba
2  from sklearn.feature_extraction.text import TfidfVectorizer
3  from sklearn.naive_bayes import MultinomialNB
4  from sklearn.model_selection import train_test_split
5  import numpy as np
6
7  class MLIntentRecognizer:
8      def __init__(self):
9          self.vectorizer = TfidfVectorizer(
10              tokenizer=lambda x: jieba.lcut(x), # 中文分词
11              max_features=1000
```

```
12         )
13         self.classifier = MultinomialNB()
14         self.is_trained = False
15
16     def train(self, texts, labels):
17         """训练模型"""
18         # 特征提取
19         X = self.vectorizer.fit_transform(texts)
20
21         # 训练分类器
22         self.classifier.fit(X, labels)
23         self.is_trained = True
24
25         print("✅ 模型训练完成! ")
26
27     def predict(self, text):
28         """预测意图"""
29         if not self.is_trained:
30             return {"error": "模型未训练"}
31
32         # 特征提取
33         X = self.vectorizer.transform([text])
34
35         # 预测意图
36         intent = self.classifier.predict(X)[0]
37
38         # 获取置信度
39         probas = self.classifier.predict_proba(X)[0]
40         confidence = float(np.max(probas))
41
42         return {
43             "intent": intent,
44             "confidence": confidence
45         }
46
47     # 准备训练数据
48     texts = [
49         "今天天气怎么样", "北京现在多少度", "会下雨吗", "明天晴天吗",
50         "帮我订一张机票", "买票去上海", "预订高铁票", "购买火车票",
51         "我的订单到哪了", "快递什么时候到", "查询物流", "包裹在哪",
52         "我要退款", "申请退货", "不想要了", "退钱",
53         "转人工客服", "找客服", "人工服务", "联系客服"
54     ]
55
56     labels = [
57         "查询天气", "查询天气", "查询天气", "查询天气",
58         "订票", "订票", "订票", "订票",
59         "查询订单", "查询订单", "查询订单", "查询订单",
60         "退款", "退款", "退款", "退款",
61         "人工客服", "人工客服", "人工客服", "人工客服"
62     ]
63
64     # 训练模型
65     recognizer = MLIntentRecognizer()
66     recognizer.train(texts, labels)
67
68     # 测试
69     test_cases = [
70         "今天会不会下雨",
71         "我想买张去广州的票",
72         "订单什么时候能到",
73         "能退货吗",
```

```
74     "我要找人工"
75 ]
76
77 print("\n📊 测试结果: \n")
78 for text in test_cases:
79     result = recognizer.predict(text)
80     print(f"输入: {text}")
81     print(f"意图: {result['intent']}, 置信度: {result['confidence']:.2f}")
82     print()
```

3.3 技术三：基于深度学习的意图识别（BERT）

原理

使用预训练语言模型（如BERT），理解上下文语义。



BERT的优势

- ✓ 理解上下文
- ✓ 处理复杂语句
- ✓ 泛化能力强
- ✓ 准确率高

代码实现

代码块

```
1 from transformers import BertTokenizer, BertForSequenceClassification
```



```
2 import torch
3 import torch.nn.functional as F
4
5 class BERTIntentRecognizer:
6     def __init__(self, model_name='bert-base-chinese'):
7         """初始化BERT模型"""
8         self.tokenizer = BertTokenizer.from_pretrained(model_name)
9         self.model = None
10        self.intent_labels = []
11
12    def prepare_data(self, texts, labels):
13        """准备训练数据"""
14        # 获取唯一的标签
15        self.intent_labels = list(set(labels))
16
17        # 将标签转为数字
18        label_to_id = {label: i for i, label in
19enumerate(self.intent_labels)}
20        numeric_labels = [label_to_id[label] for label in labels]
21
22        # 分词和编码
23        encodings = self.tokenizer(
24            texts,
25            padding=True,
26            truncation=True,
27            max_length=128,
28            return_tensors='pt'
29        )
30
31        return encodings, torch.tensor(numeric_labels)
32
33    def train(self, texts, labels, epochs=3):
34        """训练BERT模型"""
35        print("🚀 开始训练BERT模型...")
36
37        # 准备数据
38        encodings, numeric_labels = self.prepare_data(texts,
39labels)
40
41        # 初始化模型
42        num_labels = len(self.intent_labels)
43        self.model = BertForSequenceClassification.from_pretrained(
44            'bert-base-chinese',
45            num_labels=num_labels
46        )
47
48        # 优化器
49        optimizer = torch.optim.AdamW(self.model.parameters(),
50lr=2e-5)
51
52        # 训练循环
53        self.model.train()
54        for epoch in range(epochs):
55            optimizer.zero_grad()
56
57            outputs = self.model(
58                input_ids=encodings['input_ids'],
59                attention_mask=encodings['attention_mask'],
60                labels=numeric_labels
61            )
62
63            loss = outputs.loss
```



```
61         loss.backward()
62         optimizer.step()
63
64         print(f"Epoch {epoch+1}/{epochs}, Loss:
65         {loss.item():.4f}")
66
67         print("✅ BERT模型训练完成! ")
68
69     def predict(self, text):
70         """预测意图"""
71         if self.model is None:
72             return {"error": "模型未训练"}
73
74         # 编码输入
75         encoding = self.tokenizer(
76             text,
77             padding=True,
78             truncation=True,
79             max_length=128,
80             return_tensors='pt'
81         )
82
83         # 预测
84         self.model.eval()
85         with torch.no_grad():
86             outputs = self.model(
87                 input_ids=encoding['input_ids'],
88                 attention_mask=encoding['attention_mask']
89             )
90
91         # 获取概率分布
92         probas = F.softmax(outputs.logits, dim=1)
93         confidence, pred_idx = torch.max(probas, dim=1)
94
95         intent = self.intent_labels[pred_idx.item()]
96
97         return {
98             "intent": intent,
99             "confidence": float(confidence.item()),
100             "all_probabilities": {
101                 self.intent_labels[i]: float(probas[0][i])
102                 for i in range(len(self.intent_labels))
103             }
104         }
105
106     # 使用示例
107     # 注意: 需要先安装 transformers: pip install transformers torch
```

🔧 第四章：从零开始：手把手搭建意图识别系统

4.1 系统架构设计



```

20         # 3. 转小写 (对英文)
21         text = text.lower()
22
23         return text
24
25     def tokenize(self, text):
26         """分词"""
27         return jieba.lcut(text)
28
29     def remove_stopwords(self, tokens):
30         """去除停用词"""
31         return [token for token in tokens if token not in
self.stopwords]
32
33     def preprocess(self, text):
34         """完整预处理流程"""
35         # 清洗
36         text = self.clean_text(text)
37
38         # 分词
39         tokens = self.tokenize(text)
40
41         # 去停用词
42         tokens = self.remove_stopwords(tokens)
43
44         return {
45             "original": text,
46             "tokens": tokens,
47             "processed": ' '.join(tokens)
48         }
49
50     # 测试
51     preprocessor = TextPreprocessor()
52     result = preprocessor.preprocess("今天的天气怎么样啊? ? ")
53     print(result)
54     # 输出: {'original': '今天天气怎么样啊', 'tokens': ['今天', '天气', '怎
    么样', '啊'], ...}

```

4.3 第二步：槽位提取

代码块

```

1  import re
2  from datetime import datetime, timedelta
3
4  class SlotExtractor:
5      """槽位提取器"""
6
7      def __init__(self):
8          # 定义槽位模式
9          self.patterns = {
10              "城市": r'(北京|上海|广州|深圳|杭州|成都|武汉|西安)',
11              "日期": r'(今天|明天|后天|下周|周\w)',
12              "数量": r'(\d+)\s*(个|张|份|次)',
13              "价格": r'(\d+)\s*(元|块|rmb)',
14          }
15
16     def extract_slots(self, text, intent):
17         """根据意图提取槽位"""
18         slots = {}
19

```

```
20         # 根据不同意图提取不同槽位
21         if intent == "查询天气":
22             slots = self._extract_weather_slots(text)
23         elif intent == "订票":
24             slots = self._extract_booking_slots(text)
25         elif intent == "查询订单":
26             slots = self._extract_order_slots(text)
27
28         return slots
29
30     def _extract_weather_slots(self, text):
31         """提取天气查询槽位"""
32         slots = {}
33
34         # 提取城市
35         city_match = re.search(self.patterns["城市"], text)
36         if city_match:
37             slots["city"] = city_match.group(1)
38
39         # 提取日期
40         date_match = re.search(self.patterns["日期"], text)
41         if date_match:
42             slots["date"] = self._parse_date(date_match.group(1))
43         else:
44             slots["date"] = "今天"
45
46         return slots
47
48     def _extract_booking_slots(self, text):
49         """提取订票槽位"""
50         slots = {}
51
52         # 提取出发地和目的地
53         cities = re.findall(self.patterns["城市"], text)
54         if len(cities) >= 2:
55             slots["from"] = cities[0]
56             slots["to"] = cities[1]
57         elif len(cities) == 1:
58             slots["to"] = cities[0]
59
60         # 提取日期
61         date_match = re.search(self.patterns["日期"], text)
62         if date_match:
63             slots["date"] = self._parse_date(date_match.group(1))
64
65         # 提取数量
66         qty_match = re.search(self.patterns["数量"], text)
67         if qty_match:
68             slots["quantity"] = int(qty_match.group(1))
69
70         return slots
71
72     def _extract_order_slots(self, text):
73         """提取订单查询槽位"""
74         slots = {}
75
76         # 提取订单号 (示例)
77         order_pattern = r'([A-Z0-9]{10,})'
78         order_match = re.search(order_pattern, text)
79         if order_match:
80             slots["order_id"] = order_match.group(1)
81
```

```
82         return slots
83
84     def _parse_date(self, date_str):
85         """解析日期字符串"""
86         today = datetime.now()
87
88         if date_str == "今天":
89             return today.strftime("%Y-%m-%d")
90         elif date_str == "明天":
91             return (today + timedelta(days=1)).strftime("%Y-%m-%d")
92         elif date_str == "后天":
93             return (today + timedelta(days=2)).strftime("%Y-%m-%d")
94         else:
95             return date_str
96
97     # 测试
98     extractor = SlotExtractor()
99
100    # 测试天气查询
101    slots = extractor.extract_slots("明天北京天气怎么样", "查询天气")
102    print("天气槽位:", slots)
103    # 输出: {'city': '北京', 'date': '2024-xx-xx'}
104
105    # 测试订票
106    slots = extractor.extract_slots("订2张从上海到北京的票", "订票")
107    print("订票槽位:", slots)
108    # 输出: {'from': '上海', 'to': '北京', 'quantity': 2}
```

4.4 第三步：完整意图识别引擎

代码块

```
1  class IntentRecognitionEngine:
2      """完整的意图识别引擎"""
3
4      def __init__(self):
5          self.preprocessor = TextPreprocessor()
6          self.intent_recognizer = MLIntentRecognizer() # 可替换为
BERT
7          self.slot_extractor = SlotExtractor()
8
9          # 意图置信度阈值
10         self.confidence_threshold = 0.6
11
12     def process(self, text):
13         """处理用户输入"""
14         # 1. 文本预处理
15         preprocessed = self.preprocessor.preprocess(text)
16
17         # 2. 意图识别
18         intent_result = self.intent_recognizer.predict(text)
19
20         # 3. 检查置信度
21         if intent_result['confidence'] < self.confidence_threshold:
22             return {
23                 "status": "uncertain",
24                 "message": "抱歉，我没太理解您的意思，能换个说法吗？",
25                 "confidence": intent_result['confidence']
26             }
27
28         # 4. 槽位提取
```

```

29         slots = self.slot_extractor.extract_slots(
30             text,
31             intent_result['intent']
32         )
33
34         # 5. 验证必需槽位
35         missing_slots = self._check_required_slots(
36             intent_result['intent'],
37             slots
38         )
39
40         if missing_slots:
41             return {
42                 "status": "incomplete",
43                 "intent": intent_result['intent'],
44                 "slots": slots,
45                 "missing_slots": missing_slots,
46                 "message":
self._generate_slot_question(missing_slots[0])
47             }
48
49         # 6. 返回完整结果
50         return {
51             "status": "complete",
52             "intent": intent_result['intent'],
53             "confidence": intent_result['confidence'],
54             "slots": slots,
55             "preprocessed": preprocessed
56         }
57
58     def _check_required_slots(self, intent, slots):
59         """检查必需槽位"""
60         required_slots = {
61             "查询天气": ["city"],
62             "订票": ["to", "date"],
63             "查询订单": [],
64         }
65
66         required = required_slots.get(intent, [])
67         missing = [slot for slot in required if slot not in slots]
68
69         return missing
70
71     def _generate_slot_question(self, slot_name):
72         """生成槽位询问语句"""
73         questions = {
74             "city": "请问您想查询哪个城市的天气？ ",
75             "to": "请问您想去哪个城市？ ",
76             "from": "请问您从哪里出发？ ",
77             "date": "请问您打算什么时候出发？ ",
78             "quantity": "请问您需要几张票？ "
79         }
80
81         return questions.get(slot_name, f"请提供{slot_name}信息")
82
83 # 完整测试
84 engine = IntentRecognitionEngine()
85
86 # 先训练模型
87 texts = [
88     "今天天气怎么样", "北京现在多少度",
89     "帮我订票", "买张机票",

```

```
90     "订单在哪", "快递到了吗"
91 ]
92 labels = ["查询天气", "查询天气", "订票", "订票", "查询订单", "查询订
单"]
93 engine.intent_recognizer.train(texts, labels)
94
95 # 测试完整流程
96 test_inputs = [
97     "明天北京天气怎么样",
98     "我想订票去上海",
99     "查询我的订单"
100 ]
101
102 print("\n🎯 完整意图识别测试: \n")
103 for text in test_inputs:
104     result = engine.process(text)
105     print(f"输入: {text}")
106     print(f"结果: {result}")
107     print("-" * 50)
```

第五章：实战案例：智能客服机器人完整实现

5.1 项目需求

构建一个智能客服机器人，能够：

-  查询天气
-  预订机票
-  查询订单
-  处理退款
-  转人工客服
-  多轮对话记忆

智能客服机器人对话流程



完整处理流程



5.2 完整代码实现

代码块

```
1  import json
2  from datetime import datetime
3
4  class SmartCustomerServiceBot:
5      """智能客服机器人"""
6
7      def __init__(self):
8          # 初始化各个模块
9          self.engine = IntentRecognitionEngine()
10
11         # 对话历史
12         self.conversation_history = []
13
14         # 当前对话状态
15         self.current_intent = None
16         self.current_slots = {}
17
18         # 模拟数据库
19         self.mock_database = {
```



```
20         "weather": {
21             "北京": {"temp": 15, "condition": "晴天"},
22             "上海": {"temp": 20, "condition": "多云"},
23         },
24         "orders": {
25             "ORD123456": {
26                 "status": "运输中",
27                 "location": "北京分拨中心",
28                 "expected": "2024-11-25"
29             }
30         }
31     }
32
33     print("🤖 智能客服机器人已启动! ")
34     print("=" * 60)
35
36     def train(self):
37         """训练意图识别模型"""
38         print("📚 正在训练意图识别模型...")
39
40         # 训练数据
41         texts = [
42             "今天天气怎么样", "北京现在多少度", "会下雨吗", "明天晴天吗",
43             "帮我订票", "买张去上海的票", "预订机票", "购买火车票",
44             "我的订单在哪", "快递到了吗", "查询物流", "包裹什么时候到",
45             "我要退款", "申请退货", "不想要了", "能退吗",
46             "转人工", "找客服", "人工服务", "联系客服",
47             "你好", "在吗", "嗨", "hello"
48         ]
49
50         labels = [
51             "查询天气", "查询天气", "查询天气", "查询天气",
52             "订票", "订票", "订票", "订票",
53             "查询订单", "查询订单", "查询订单", "查询订单",
54             "退款", "退款", "退款", "退款",
55             "人工客服", "人工客服", "人工客服", "人工客服",
56             "问候", "问候", "问候", "问候"
57         ]
58
59         self.engine.intent_recognizer.train(texts, labels)
60         print("✅ 模型训练完成! \n")
61
62     def chat(self, user_input):
63         """处理用户消息"""
64         # 记录对话
65         self.conversation_history.append({
66             "role": "user",
67             "content": user_input,
68             "timestamp": datetime.now().isoformat()
69         })
70
71         # 意图识别
72         result = self.engine.process(user_input)
73
74         # 根据状态生成响应
75         response = self._generate_response(result)
76
77         # 记录机器人响应
78         self.conversation_history.append({
79             "role": "bot",
80             "content": response,
81             "timestamp": datetime.now().isoformat()
```

```

82         })
83
84         return response
85
86     def _generate_response(self, result):
87         """生成响应"""
88         status = result.get("status")
89
90         # 情况1: 不确定意图
91         if status == "uncertain":
92             return result["message"]
93
94         # 情况2: 槽位不完整
95         if status == "incomplete":
96             self.current_intent = result["intent"]
97             self.current_slots.update(result["slots"])
98             return result["message"]
99
100        # 情况3: 意图和槽位都完整
101        intent = result["intent"]
102        slots = result["slots"]
103
104        # 执行相应动作
105        if intent == "问候":
106            return self._handle_greeting()
107        elif intent == "查询天气":
108            return self._handle_weather_query(slots)
109        elif intent == "订票":
110            return self._handle_booking(slots)
111        elif intent == "查询订单":
112            return self._handle_order_query(slots)
113        elif intent == "退款":
114            return self._handle_refund(slots)
115        elif intent == "人工客服":
116            return self._handle_human_service()
117        else:
118            return "抱歉，我还在学习中，这个问题我暂时回答不了。 "
119
120    def _handle_greeting(self):
121        """处理问候"""
122        return "您好！我是智能客服小助手，很高兴为您服务！😊\n\n我可以帮
123        您：\n1. 查询天气\n2. 预订机票\n3. 查询订单\n4. 处理退款\n5. 转接人工客服
124        \n\n请问有什么可以帮您？ "
125
126    def _handle_weather_query(self, slots):
127        """处理天气查询"""
128        city = slots.get("city", "北京")
129        date = slots.get("date", "今天")
130
131        # 模拟查询天气API
132        weather_data = self.mock_database["weather"].get(city)
133
134        if weather_data:
135            return f"📍 {city} {date}的天气：\n" \
136                f"🌡️ 温度：{weather_data['temp']}°C\n" \
137                f"☀️ 天气：{weather_data['condition']}\n\n" \
138                f"还有其他需要帮助的吗？ "
139        else:
140            return f"抱歉，暂时没有{city}的天气信息。您可以换个城市试
141            试。 "
142
143    def _handle_booking(self, slots):

```

```

141         """处理订票"""
142         to_city = slots.get("to", "未知")
143         from_city = slots.get("from", "当前位置")
144         date = slots.get("date", "近期")
145         quantity = slots.get("quantity", 1)
146
147         # 模拟订票流程
148         order_id = f"ORD{datetime.now().strftime('%Y%m%d%H%M%S')}"
149
150         return f"👉 订票信息确认: \n" \
151             f"出发地: {from_city}\n" \
152             f"目的地: {to_city}\n" \
153             f"出发日期: {date}\n" \
154             f"票数: {quantity}张\n\n" \
155             f"订单已生成! \n" \
156             f"📄 订单号: {order_id}\n\n" \
157             f"请在30分钟内完成支付。还有其他需要吗? "
158
159     def _handle_order_query(self, slots):
160         """处理订单查询"""
161         order_id = slots.get("order_id")
162
163         if order_id and order_id in self.mock_database["orders"]:
164             order = self.mock_database["orders"][order_id]
165             return f"📦 订单查询结果: \n" \
166                 f"订单号: {order_id}\n" \
167                 f"状态: {order['status']}\n" \
168                 f"当前位置: {order['location']}\n" \
169                 f"预计送达: {order['expected']}\n\n" \
170                 f"还有其他需要帮助的吗? "
171         else:
172             return "请提供您的订单号, 格式如: ORD123456"
173
174     def _handle_refund(self, slots):
175         """处理退款"""
176         return "💰 退款流程说明: \n" \
177             "1. 请提供订单号\n" \
178             "2. 说明退款原因\n" \
179             "3. 上传商品照片 (如适用) \n" \
180             "4. 等待审核 (1-3个工作日) \n" \
181             "5. 退款将原路返回\n\n" \
182             "需要我帮您转接人工客服处理吗? "
183
184     def _handle_human_service(self):
185         """处理人工客服请求"""
186         return "正在为您转接人工客服...\n" \
187             "👤 当前排队人数: 3人\n" \
188             "🕒 预计等待时间: 2分钟\n\n" \
189             "在等待期间, 您可以继续向我咨询其他问题。"
190
191     def get_conversation_history(self):
192         """获取对话历史"""
193         return self.conversation_history
194
195     def save_conversation(self, filename="conversation_log.json"):
196         """保存对话记录"""
197         with open(filename, 'w', encoding='utf-8') as f:
198             json.dump(self.conversation_history, f,
199                       ensure_ascii=False, indent=2)
200         print(f"📝 对话记录已保存到 {filename}")
201
202     # ===== 使用示例 =====

```

第六章：进阶技巧：多意图识别与置信度…



4月1日 08:06

第六章和第七章感觉很多实际工程中能用到的, 能不能再多讲讲?

```
203
204 def main():
205     # 创建机器人
206     bot = SmartCustomerServiceBot()
207
208     # 训练模型
209     bot.train()
210
211     # 模拟对话
212     print("💬 开始对话（输入 'quit' 退出）\n")
213     print("=" * 60)
214
215     while True:
216         user_input = input("\n👤 您： ")
217
218         if user_input.lower() in ['quit', 'exit', '退出']:
219             print("\n👋 感谢使用！再见！ ")
220             bot.save_conversation()
221             break
222
223         if not user_input.strip():
224             continue
225
226         # 获取机器人响应
227         response = bot.chat(user_input)
228         print(f"\n🤖 客服： {response}")
229
230 if __name__ == "__main__":
231     main()
```

5.3 运行效果示例

代码块

```
1  🤖 智能客服机器人已启动！
2  =====
3  📖 正在训练意图识别模型...
4  ✅ 模型训练完成！
5
6  💬 开始对话（输入 'quit' 退出）
7
8  =====
9
10 👤 您： 你好
11
12 🤖 客服： 您好！我是智能客服小助手,很高兴为您服务！ 😊
13
14 我可以帮您：
15 1. 查询天气
16 2. 预订机票
17 3. 查询订单
18 4. 处理退款
19 5. 转接人工客服
20
21 请问有什么可以帮您？
22
23 👤 您： 明天北京天气怎么样
24
25 🤖 客服： 📍 北京 2024-11-23的天气：
26 🌡️ 温度： 15°C
27 🌞 天气：晴天
```

28
29 还有其他需要帮助的吗?
30
31 👤 您: 帮我订2张去上海的票
32
33 🤖 客服: ✈️ 订票信息确认:
34 出发地: 当前位置
35 目的地: 上海
36 出发日期: 近期
37 票数: 2张
38
39 订单已生成!
40 📄 订单号: ORD20241122153045
41
42 请在30分钟内完成支付。还有其他需要吗?
43
44 👤 您: 查询订单ORD123456
45
46 🤖 客服: 📦 订单查询结果:
47 订单号: ORD123456
48 状态: 运输中
49 当前位置: 北京分拨中心
50 预计送达: 2024-11-25
51
52 还有其他需要帮助的吗?

🚀 第六章：进阶技巧：多意图识别与置信度评分


6.1 处理多意图场景

有时用户一句话包含多个意图：

例子：

- "帮我查一下明天北京的天气，然后订张去上海的票"
 - 意图1: 查询天气（北京，明天）
 - 意图2: 订票（去上海）

多意图识别处理



6.2 多意图识别实现

代码块

```
1 class MultiIntentRecognizer:
2     """多意图识别器"""
3
4     def __init__(self):
5         self.single_recognizer = IntentRecognitionEngine()
6
7     def split_sentence(self, text):
8         """拆分复合句子"""
9         # 使用连词分割
10        separators = ['然后', '接着', '还有', '另外', '以及', '和']
11
12        parts = [text]
13        for sep in separators:
14            new_parts = []
15            for part in parts:
16                new_parts.extend(part.split(sep))
17            parts = new_parts
18
19        return [p.strip() for p in parts if p.strip()]
20
21    def recognize(self, text):
22        """识别多意图"""
23        # 拆分句子
24        parts = self.split_sentence(text)
25
26        # 识别每个部分的意图
27        results = []
28        for i, part in enumerate(parts):
29            result = self.single_recognizer.process(part)
```

```

30         result['sequence'] = i + 1
31         results.append(result)
32
33     return {
34         "has_multiple_intents": len(results) > 1,
35         "intents": results
36     }
37
38 # 测试
39 multi_recognizer = MultiIntentRecognizer()
40 text = "帮我查明天北京天气，然后订张去上海的票"
41 result = multi_recognizer.recognize(text)
42
43 print("多意图识别结果:")
44 for intent in result['intents']:
45     print(f" 意图{intent['sequence']}: {intent['intent']}")

```

6.3 置信度校准

代码块

```

1  class ConfidenceCalibrator:
2      """置信度校准器"""
3
4      def __init__(self):
5          self.thresholds = {
6              "high": 0.85,    # 高置信度
7              "medium": 0.6,   # 中等置信度
8              "low": 0.3       # 低置信度
9          }
10
11     def calibrate(self, intent, confidence):
12         """校准置信度"""
13         if confidence >= self.thresholds["high"]:
14             return {
15                 "intent": intent,
16                 "confidence": confidence,
17                 "level": "high",
18                 "action": "直接执行",
19                 "message": None
20             }
21
22         elif confidence >= self.thresholds["medium"]:
23             return {
24                 "intent": intent,
25                 "confidence": confidence,
26                 "level": "medium",
27                 "action": "二次确认",
28                 "message": f"您是想{intent}吗? "
29             }
30
31         elif confidence >= self.thresholds["low"]:
32             return {
33                 "intent": intent,
34                 "confidence": confidence,
35                 "level": "low",
36                 "action": "提供选项",
37                 "message": f"您可能想: \n1. {intent}\n2. 其他...\n请选择"
38             }
39

```



```
40         else:
41             return {
42                 "intent": "未知",
43                 "confidence": confidence,
44                 "level": "very_low",
45                 "action": "拒绝识别",
46                 "message": "抱歉，我没太理解，能换个说法吗？"
47             }
48
49 # 使用示例
50 calibrator = ConfidenceCalibrator()
51
52 # 测试不同置信度
53 test_cases = [
54     ("查询天气", 0.95),
55     ("订票", 0.7),
56     ("退款", 0.4),
57     ("未知意图", 0.1)
58 ]
59
60 for intent, conf in test_cases:
61     result = calibrator.calibrate(intent, conf)
62     print(f"意图: {intent}, 置信度: {conf}")
63     print(f"处理方式: {result['action']}")
64     if result['message']:
65         print(f"消息: {result['message']}")
66     print()
```

第七章：常见问题与优化策略

7.1 常见问题汇总

问题1：识别准确率低

原因：

- 训练数据不足
- 意图分类过于模糊
- 缺少上下文信息

解决方案：

代码块

```
1  # 1. 数据增强
2  def augment_data(text):
3      """数据增强"""
4      variations = []
5
6      # 同义词替换
7      synonyms = {
8          "查询": ["查看", "看看", "了解"],
9          "订票": ["买票", "购买", "预订"],
10     }
11
12     for original, syns in synonyms.items():
13         if original in text:
```



```
14         for syn in syns:
15             variations.append(text.replace(original, syn))
16
17     return variations
18
19 # 2. 增加训练样本
20 original_data = ["查询天气"]
21 augmented_data = augment_data(original_data[0])
22 print(augmented_data)
23 # ['查看天气', '看看天气', '了解天气']
```

问题2：多轮对话记忆丢失

解决方案：

代码块

```
1 class ConversationMemory:
2     """对话记忆管理器"""
3
4     def __init__(self, max_history=10):
5         self.history = []
6         self.max_history = max_history
7         self.context = {}
8
9     def add_turn(self, user_input, bot_response, intent, slots):
10        """添加对话轮次"""
11        turn = {
12            "user": user_input,
13            "bot": bot_response,
14            "intent": intent,
15            "slots": slots,
16            "timestamp": datetime.now()
17        }
18
19        self.history.append(turn)
20
21        # 更新上下文
22        self.context.update(slots)
23
24        # 保持历史记录在限制内
25        if len(self.history) > self.max_history:
26            self.history = self.history[-self.max_history:]
27
28    def get_context(self):
29        """获取当前上下文"""
30        return self.context
31
32    def get_last_intent(self):
33        """获取上一轮意图"""
34        if self.history:
35            return self.history[-1]["intent"]
36        return None
```

7.2 性能优化建议

优化1：模型缓存

代码块

```

1  import pickle
2
3  class ModelCache:
4      """模型缓存"""
5
6      @staticmethod
7      def save_model(model, filename):
8          """保存模型"""
9          with open(filename, 'wb') as f:
10              pickle.dump(model, f)
11              print(f"✅ 模型已保存到 {filename}")
12
13      @staticmethod
14      def load_model(filename):
15          """加载模型"""
16          with open(filename, 'rb') as f:
17              model = pickle.load(f)
18              print(f"✅ 模型已从 {filename} 加载")
19              return model
20
21  # 使用
22  # 训练后保存
23  ModelCache.save_model(recognizer, "intent_model.pkl")
24
25  # 下次直接加载
26  recognizer = ModelCache.load_model("intent_model.pkl")

```

优化2：批量处理

代码块

```

1  def batch_predict(recognizer, texts, batch_size=32):
2      """批量预测"""
3      results = []
4
5      for i in range(0, len(texts), batch_size):
6          batch = texts[i:i+batch_size]
7          batch_results = [recognizer.predict(text) for text in
8              batch]
9          results.extend(batch_results)
10
11      return results

```

7.3 评估指标

代码块

```

1  from sklearn.metrics import classification_report, confusion_matrix
2
3  def evaluate_model(recognizer, test_texts, test_labels):
4      """评估模型性能"""
5      predictions = [recognizer.predict(text)['intent']
6                      for text in test_texts]
7
8      # 分类报告
9      print("📊 分类报告:")
10     print(classification_report(test_labels, predictions))
11
12     # 混淆矩阵
13     print("\n📊 混淆矩阵:")

```

```
14     print(confusion_matrix(test_labels, predictions))
15
16     # 准确率
17     accuracy = sum(p == l for p, l in zip(predictions,
test_labels)) / len(test_labels)
18     print(f"\n✅ 总体准确率: {accuracy:.2%}")
```

全文评论

- 

4月11日 04:42
很牛逼很详细
- 

4月14日 17:15
建议做个 Java 版的
- 

5月13日 20:52
非常到位了，入门选手非常喜欢
- 

6月3日 17:39
收获颇多
- 

6月6日 10:31
无敌 牛逼
- 

7月5日 23:52
看得半知半懂
- 

7月20日 22:42
牛逼，通俗易懂
- 

1 小时前
有些模型和处理方式有点滞后 可以更新一下吗